


Génome Réunion : La Mathématique de l'Équité Génomique

De la puce SNP au séquençage WGS :
ouvrir la boîte noire de la sélection
génomique.

Transformer la diversité biologique en donnée de
référence par l'optimisation mathématique.

L'Angle Mort de la Médecine de Précision : L'Injustice Épistémique



Biais de représentation massif

Plus de 81% des bases mondiales (gnomAD, GWAS) reposent sur des génomes d'ascendance européenne. L'ascendance africaine représente à peine 1,1%.

L'échec de l'extrapolation

Les populations fortement métissées (admixed) sont structurellement absentes.

Conséquence clinique

Perte de fiabilité des algorithmes d'imputation, biais dans les scores de risque polygénique (PRS), et errance diagnostique accrue.

L'Intelligence Artificielle et la médecine ciblée reproduisent ces biais. Ne pas agir, c'est accepter une innovation médicale exclusive.

La Double Singularité Génomique de La Réunion



Panneau 1 : Métissage Multi-continental Extrême

Une recomposition génétique intégrale sur un territoire vierge. Des combinaisons alléliques uniques au monde issues des flux migratoires historiques.

Panneau 2 : L'Effet Fondateur

Des goulots d'étranglement démographiques sévères créant une dérive génétique. Conséquence : Fixation de variants rares et prévalence locale élevée de maladies autosomiques récessives.

Le Défi : Comment capturer cette immense complexité sans séquencer l'intégralité d'une population de 800 000 habitants ?

Partie 1 : Le Cadre d'Optimisation Statistique

C = Cohorte initiale
génomotypée (Données
massives, coût faible)

N = Nombre maximal
d'individus séquençables

B = Budget limite du
projet

$$\max_{S \subset C, |S|=N} I(S) \text{ sous} \\ \text{contrainte} \\ \text{de Coût}(S) \leq B$$


S = Sous-ensemble
sélectionné pour le
WGS (haute valeur)

I(S) = L'Information
nouvelle (Diversité,
Profils centraux,
Fondateur)

Principe Fondamental : Séquencer au hasard est inefficace. Nous devons concevoir une fonction algorithmique pour maximiser le rendement informatif de chaque euro investi.

Le Design en Deux Temps : De la Puce au Séquençage

Optimization Funnel




Étape 1 : Puce SNP (Économique & Exhaustif).
Déploiement sur l'ensemble de la cohorte EFS
pour cartographier la structure génétique globale
à moindre coût.

Étape 2 : Sélection Mathématique (Le Filtre).
Calcul de scores composites pour identifier les
profils maximisant l'information nouvelle $I(S)$.

Étape 3 : Séquençage WGS (Coûteux & Précis).
Séquençage complet uniquement sur le sous-
ensemble S optimisé.

Conclusion : Ce n'est pas un échantillonnage aléatoire,
mais une optimisation dirigée par la donnée observable.

Partie 2 : Cartographier l'Espace Génétique (Le Trio)



Coordonnée 1 : PCA (z_i)

Position Spatiale. Positionne l'individu dans l'espace génétique mondial. Repère les clusters et profils extrêmes.

$$z_i = (PC_{i1}, PC_{i2}, \dots, PC_{ip})$$

Coordonnée 2 : ADMIXTURE (q_i)

Proportions d'Ascendance. Vecteur de composition ancestrale globale (ex: % Afrique, % Europe, % Asie).

$$q_i = (q_{i1}, \dots, q_{iK})$$

Coordonnée 3 : Entropie (H_i)


Degré de Métissage. Résume l'intensité du mélange.

$$H_i \approx 0 \text{ (concentré)}, H_i \approx 1 \text{ (fortement métissé)}.$$

Règle Mathématique : Deux individus peuvent être proches en PCA mais différer structurellement en ascendance. Le trio est non-négociable.


Partie 3 : La Cascade de Résolution du Métissage

Niveau 1 : Exploration (PCA Globale)



Cadrage. Repère les grands axes de variation et sélectionne les populations sources plausibles.

Niveau 2 : Modélisation (ADMIXTURE)



Choix du paramètre global K.
Estime les proportions d'ascendance pour l'ensemble du jeu de données.

Niveau 3 : Résolution (Local Ancestry)



Validation fine. Attribution d'une origine spécifique segment par segment sur le chromosome pour résoudre les ambiguïtés.

Distinction Critique : Modèle Global vs. Ambiguïté Locale

Définir K (Le Modèle Global)

- Tester une grille de K par Cross-Validation (CV).
- Vérifier la stabilité entre les itérations.


Règle : K est un paramètre global mesurant la complexité du modèle, pas un attribut individuel.

Traiter les Zones Ambiguës (Le Signal Local)

- Un segment mal assigné peut refléter : un panel de référence incomplet, des populations trop proches, ou une ascendance ancienne.

La Décision Pratique : Ne pas augmenter K aveuglément. Un segment non résolu n'est pas la preuve d'une nouvelle ascendance, c'est un signal d'investigation locale nécessitant un panel enrichi.

Partie 4 : Le Moteur d'Optimisation — Couvrir Plus, Répéter Moins



Force 1 : Maximiser l'Information (Distances)

- Distance PCA (D_i^{PCA}) : Sélectionner les profils qui explorent des zones vierges du nuage génétique.
- Distance Admixture (D_i^{ADM}) : Explorer des vecteurs d'ascendance inédits.

Force 2 : Minimiser la Redondance (Force Field)

- Pénalité de Parenté ($P_i^{kin} = 1 - \varphi_i^{max}$) :
 - Où φ_i^{max} est la parenté maximale avec les individus déjà sélectionnés.
- Mécanique : On empêche le séquençage d'individus génétiquement trop proches. Chaque sélection crée un champ de répulsion mathématique autour d'elle.

La Matrice à Deux Bras : Architecture du Score Composite

Bras 1 : Bras Diversité (Le Métissage)	Bras 2 : Bras Fondateur (L'Histoire Insulaire)
Objectif : Couverture globale de l'espace génétique et du métissage.	Objectif : Capturer les mutations spécifiques à l'île issues des goulots d'étranglement.
Variables Clés : PCA, Admixture globale, Faible parenté.	Variables Clés : Autozygotie (ROH), Identité par descendance (IBD).
$S_i^{\text{div}} = 0.45(D_i^{\text{PCA}}) + 0.25(D_i^{\text{ADM}}) + 0.15(1 - \varphi_i^{\text{max}}) + 0.10(U_i) + 0.05(\text{DNAQ}_i)$	$S_i^{\text{fond}} = 0.40(\text{ROHscore}_i) + 0.20(\text{IBDscore}_i) + 0.15(D_i^{\text{ADM}}) + 0.15(U_i) + 0.10(\text{DNAQ}_i)$

Conclusion : Une pondération transparente. Deux objectifs biologiques distincts nécessitent deux moteurs mathématiques distincts.

Partie 5 : Le Pipeline Opérationnel en 10 Étapes

[Amont] Préparation & Structure

[Centre] L'Engine Mathématique

[Aval] Contrôle

- 1 QC (Échantillons + SNPs)
- 2 LD-pruning et PCA Globale
- 3 ADMIXTURE pour vecteur q
- 4 Calcul de Parenté et IBD
- 5 Détection des segments ROH

6. Application des quotas souples

7. Identification des profils centraux par cluster

8. **Sélection gloutonne : Bras Diversité**

9. **Sélection dirigée : Bras Fondateur**

10. Ajout du bras technique et Validation finale

La Validation Finale : Une Méthodologie Défendable


Le Principe de Transparence :

Le séquençage WGS n'est plus une boîte noire.

Le design Puce SNP -> Score -> WGS est **auditable**.

Les 5 Contrôles de Validation Documentés :

- **Concordance** de la distribution PCA (Panel vs Cohorte).
- **Représentativité** des proportions d'admixture (q) et d'entropie (H_i).
- **Contrôle de la parenté maximale** interne stricte.
- **Couverture complète** des strates géographiques/cliniques.
- **Respect des quotas** par bras (Diversité / Fondateur).



Conclusion Technique : Des variables définies. Des poids annoncés. Un algorithme 100% reproductible.

De l'Optimisation Mathématique à l'Équité Clinique



Le Modèle

Articuler un modèle global robuste avec une lecture locale fine.

L'Impact (Soin)

Sécurisation pharmacogénétique (ex: Warfarine) et fin de l'errance diagnostique.

L'Impact (Recherche)

Transformer La Réunion de point aveugle en modèle mondial de diversité.

La mathématique de Génome Réunion ne sélectionne pas seulement des données ; elle recalibre les standards de demain pour garantir une médecine de précision véritablement équitable à l'horizon 2030.