

Abstract :

Les recherches récentes et nos observations quotidiennes lors de nos tests génétiques destinés au diagnostic, effectués dans notre laboratoire, ont montré que les séquences génomiques de référence actuellement utilisées pour l'interprétation des résultats ne reflètent pas l'ensemble de la variabilité génétique mondiale.

Ce manque d'information est lié à la surreprésentation des populations d'ascendance européenne au sein des bases de données génomiques internationales, ce qui diminue la valeur de ces références pour les applications cliniques, la recherche et les analyses génétiques. Cela crée, de fait, une inégalité dans la qualité du rendu diagnostique et l'efficacité des traitements pour d'autres groupes ethniques, comme la population de l'île de La Réunion.

Consciente de ce problème, la communauté scientifique a initié plusieurs projets visant à y remédier. Dans ce contexte, nous présentons ici l'intérêt et la méthodologie prévue pour la création d'un projet de génome de référence spécifique à la population réunionnaise. L'échantillonnage sera réalisé auprès de donneurs volontaires de l'Établissement Français du Sang (EFS), en s'assurant qu'il représente fidèlement la diversité génétique de l'île. Les extractions d'ADN seront effectuées au laboratoire de génétique du CHU de La Réunion.

Les échantillons seront génotypés à l'aide de la technologie iScan d'Illumina, permettant des analyses approfondies de la structure génétique de la population via des analyses en composantes principales (PCA) et l'étude de l'admixture (métissage). Ces analyses permettront de sélectionner des échantillons représentatifs qui seront envoyés pour un séquençage global auprès du consortium POPgen.

Les données issues de ce séquençage permettront la création d'une base de données de variants spécifique à la population réunionnaise. Cette ressource facilitera des études approfondies sur les variants génétiques propres aux Réunionnais, notamment en ce qui concerne les liens entre certaines pathologies et ces variations génétiques. De plus, une analyse détaillée de l'admixture sera menée pour explorer les interactions entre pharmacogénétique et métissage, ainsi que d'autres aspects de l'évolution et de l'épidémiologie propres à cette population.

Ce projet est particulièrement pertinent à La Réunion, où, en raison de l'histoire complexe des migrations et de l'isolement de l'île, on observe une plus grande prévalence de maladies à effet fondateur et de mutations spécifiques. Les bénéfices attendus de ce projet incluent des avancées en biologie humaine, une amélioration de la prise en charge clinique grâce au développement de thérapies géniques personnalisées, l'identification de pharmacorésistances et l'optimisation du rendu des résultats génétiques.

En définitive, ce projet vise non seulement à améliorer la santé des Réunionnais en adaptant les outils génétiques à leurs spécificités, mais également à enrichir la compréhension globale de la diversité génétique humaine, offrant ainsi un modèle pour d'autres populations sous-représentées dans les référentiels génomiques actuels.

Mots-clés : Génome de référence, La Réunion, diversité génétique, génétique des populations, séquençage génomique, admixture, PCA, variants génétiques.

Abstract:

Recent research and our daily observations during genetic diagnostic testing in our laboratory have shown that the reference genomic sequences currently used for result interpretation do not fully reflect the global genetic diversity.

This lack of representation is primarily due to the overrepresentation of populations of European ancestry in international genomic databases, which reduces the clinical, research, and analytical value of these references. Consequently, this creates an inequality in diagnostic accuracy and treatment effectiveness for other ethnic groups, including the population of La Réunion.

Aware of this issue, the scientific community has initiated several projects to address it. In this context, we present the rationale and methodology for developing a population-specific reference genome for La Réunion. Sampling will be conducted among voluntary donors from the French Blood Establishment (EFS), ensuring that the sample accurately represents the island's genetic diversity. DNA extractions will be performed at the genetics laboratory of the University Hospital of La Réunion (CHU de La Réunion).

The samples will be genotyped using Illumina's iScan technology, enabling in-depth analyses of the population's genetic structure through principal component analysis (PCA) and admixture studies. These analyses will help select representative samples for whole-genome sequencing in collaboration with the POPgen consortium.

The sequencing data will contribute to the creation of a population-specific variant database for La Réunion. This resource will facilitate advanced studies on genetic variants unique to Réunionese individuals, particularly regarding their associations with certain diseases. Furthermore, a detailed admixture analysis will be conducted to explore the interactions between pharmacogenetics and genetic diversity, along with other aspects of population evolution and epidemiology.

This project is particularly relevant in La Réunion, where the island's complex migration history and geographical isolation have led to a higher prevalence of founder-effect diseases and specific mutations. Expected benefits include advances in human biology, improved clinical management through the development of personalized genetic therapies, identification of pharmacoresistance mechanisms, and optimization of genetic diagnostic tools.

Ultimately, this project aims not only to enhance healthcare for Réunionese individuals by tailoring genetic tools to their specific needs but also to contribute to the broader understanding of human genetic diversity, providing a model for other underrepresented populations in current genomic reference databases.

Keywords: Reference genome, La Réunion, genetic diversity, population genetics, genomic sequencing, admixture, PCA, genetic variants.

Sommaire à insérer

1. Introduction

La population de l'île de la Réunion est un regroupement de diverses communautés qui s'est créé par des apports successifs migratoires tout au long de son histoire. On y retrouve un large éventail de diverses origines ethniques : Africaine, chinoise, indienne, européenne, eurasienne.



Malgré des périodes marquées par des lois discriminatoires comme le « Code Noir » durant l'esclavage, les interactions interethniques ont toujours existé. Aujourd'hui, La Réunion incarne un exemple dynamique de multiculturalisme et de créolisation, où le respect mutuel et l'interaction constante entre les différentes communautés ont forgé un peuple profondément métissé.

Au-delà de cette incroyable richesse culturelle qui d'écoule de son histoire, les conséquences génétiques dues au métissage qu'elles soient positives ou délétères reste largement méconnues. L'analyse du métissage est complexe, en raison des modèles mathématiques et des outils d'analyse qui ne sont disponibles que depuis peu de temps grâce aux progrès du big data et du séquençage haut débit.

Dans le cadre quotidien de nos études génétiques, que ce soit pour des diagnostics constitutionnels ou somatiques, nous devons comparer la séquence de l'échantillon à tester avec une séquence de référence du génome humain. Cette séquence de référence a été très coûteuse à réaliser, et le projet de sa création a donc été divisé entre différents pays occidentaux. Des recherches récentes ont révélé que la séquence de référence utilisée comme standard de comparaison, ainsi que les bases de données génétiques associées, telles que SNPdb (NCBI), sont majoritairement basées sur des populations d'origine Européenne. Les données actuelles ne montrent que partiellement la diversité mondiale. Ainsi, 7/8 de la population mondiale

environs est sous-représentée ou non étudiée. En 2016, Rasika AM et al, publié une étude dans laquelle ils ont séquencé 642 individus issu de différentes communautés afro-mêlé d'Amérique du Nord et du Sud, des Caraïbes et d'Afrique de l'Ouest, montrant qu'il existait plusieurs millions de variants non représentés dans la séquence de référence ainsi que dans les bases de données qui y sont rattachées [1]. Concluant leur publication par la pertinence d'une meilleure représentation de la diversité ethnique au sein des bases de données génétique mondial. Depuis, de nombreuses publications confirment clairement cette inégalité de traitement [2][3].

Avec la richesse des ascendances de la population Réunionnaise et de son métissage, la séquence de référence utilisé n'est pas adaptée à la population Réunionnaise. Bien que faute de mieux, les diagnostics et études génétiques réalisés par notre service ou par divers laboratoires en métropole l'utilise au quotient.

Nous savons aujourd'hui qu'une partie, plus ou moins grande, des variations de susceptibilité liées à l'ethnicité, n'est tout simplement pas prise en compte car inconnue.

Toutes les études sanitaires, telles que celles de l'ARS concernant les différences négatives du taux de survie au cancer entre La Réunion et la métropole (2008-2018) [4] ou diverses maladies chroniques comme le diabète, sont souvent expliquées uniquement par des facteurs sociaux. Bien que cet argument soit pertinent, il ne suffit pas à expliquer les écarts importants entre ces deux régions.

Sans tenir compte de la diversité ethnique de la population réunionnaise, comment comparer de manière pertinente ces données médicales alors que les bases de comparaison sont aux mieux partiels ?

Ce manque de données génétiques spécifiques à la population réunionnaise crée un biais défavorable et réduit considérablement les chances de combler l'écart entre les populations métropolitaine et réunionnaise [5][6][12].

L'absence de représentation des variants génétiques réunionnais dans les bases de données internationales soulève un autre problème aussi grave que l'identification de la présence ou non de mutations de susceptibilité ou d'orientations thérapeutiques.

Depuis quelques années, l'industrie pharmaceutique utilise les données de la séquence de référence actuelle dans la conception de médicaments pour en déterminer l'efficacité [7][8][9]. Par conséquent, il est probable que les médicaments fabriqués aujourd'hui soient optimisés principalement pour des patients d'origine Européenne, non pas par intention délibérée, mais simplement parce que la séquence de référence n'est pas représentative des autres groupes ethniques. Cela souligne la nécessité de diversifier les séquences de référence pour garantir que les traitements médicaux soient adaptés à une plus grande diversité de populations [12].

Il est pertinent de se poser la question de l'efficacité des traitements pour d'autres types ethniques, ou comme c'est le cas pour La Réunion, pour des populations fortement métissées.

De plus, avec l'essor de l'intelligence artificielle (IA) dans le domaine pharmaceutique, non seulement pour tester mais aussi désormais pour concevoir des traitements ciblant mieux les pathologies sur une base génétique ^{[10][11]}, le problème risque de s'aggraver. L'apprentissage de ces IA repose sur les données qui leur sont fournies. Par conséquent, il est fort probable que les futurs traitements soient encore mieux adaptés aux populations caucasiennes, ce qui pourrait accentuer les inégalités de santé entre La Réunion et la métropole.

L'objectif principal de ce projet est de corriger les disparités de traitement génétique en créant une base de données complète des variants présents dans la population réunionnaise. Cette initiative vise à établir une séquence de référence spécifiquement adaptée à La Réunion, reflétant pleinement sa diversité et son métissage unique. Cette nouvelle base de données sera intégrée aux bases de données internationales telles que HapMap, en collaboration avec le CEPH, afin que les variations spécifiques de résistance aux médicaments et de susceptibilité au cancer soient prises en compte dans le développement de nouveaux traitements et dans l'interprétation des résultats des diagnostics génétiques.

Le projet a également un objectif secondaire : étudier l'évolution de la population réunionnaise et son admixture. Cette étude fournira des indicateurs précieux et des simulations pour les études épidémiologiques, contribuant ainsi à améliorer la prise de décision dans le suivi médical à La Réunion. Les données recueillies seront mises à disposition de la communauté scientifique locale et internationale, servant de base à des recherches futures pour approfondir la compréhension des particularités génétiques de cette population.

1.1. Contexte international : la diversité génétique mondiale dans les bases de données


Après l'enthousiasme suscité par la première séquence complète du génome humain en avril 2003 (HGP : Human Genome Project), des questions se sont rapidement posées sur la pertinence des données en ce qui concerne la diversité ethnique des échantillons. Il est apparu que les bases de données du NIH, créées pour la communauté scientifique, représentaient très mal la diversité humaine. En 2009, 96 % des séquences génomiques provenaient d'individus d'origine européenne [13][2].

Des efforts significatifs ont été faits pour accroître la diversité ethnique dans les séquençages. Le projet 1000 Genomes, lancé en 2008, en est un exemple. Son objectif était de séquencer 1000 génomes issus de 26 populations différentes. Les premiers résultats de ce projet ont été publiés en 2010 [14]. Cette contribution a permis de commencer de nombreuses études sur différentes populations autres que d'origine Européenne, telle que sur la population africaine [15].

Depuis d'autres bases de données ont vu le jour

- **H3Africa** (Human Heredity and Health in Africa) créé en 2010 à l'initiative du NIH dont l'objectif principal est de promouvoir la recherche génomique sur le continent Africain [16].

Figure 1 Répartition des populations africaines dans H3Africa




Répartition approximative déduite à partir de publications, car il n'existe aucun référencement précis

- **ExAC** (Exome Aggregation Consortium) créé en 2014 qui regroupe l'étude de plusieurs dizaines de milliers d'exomes issus de populations diversifiées [17][18].

- **GnomAD** (Genome Aggregation Database) qui a été lancé en 2016. Il est une extension du projet ExAC, visant à inclure non seulement les données exomiques, mais également les génomes complets de centaines de milliers d'individus d'ethnie différentes ^[19].


Figure 2 Répartition des populations dans gnomAD



Répartition calculée à partir de 141 456 échantillons ^[19]


- **Chinese Millionome Database** créé en 2017 et qui vise à référencer les variants de 1 000 000 individus de la population Han ^[20].
- **Korean Reference Genome Database (KRGDB)** créé en 2017, Cette base de données vise à servir de référence pour les chercheurs travaillant sur la génétique humaine et la médecine personnalisée en Corée ^{[21][22]}.
- **Indian Genome Variation Database (IGVdb)** créé en 2005 est une ressource majeure qui a été créée pour cataloguer la diversité génétique des populations indiennes. Ce projet vise à mieux comprendre la diversité génétique complexe en Inde, où de nombreux groupes ethniques. ^[23]
- La **Japanese Genotype-phenotype Archive (JGPA)** est une base de données destinée à stocker des informations génétiques et phénotypiques issues de la population japonaise. ^[24]

Figure 3 Répartition des échantillons dans la population Asiatique



Malgré une nette augmentation de la variabilité ethnique surtout grâce aux l'études plus important réalisées en Asie ces dernières années, certaine région du monde reste cependant très sous représentée, comme la population Africain.

Figure 4 Représentation de la variabilité ethnique continental 2021



1.2. Les biais de représentation dans les génomes de référence

Les génomes de référence jouent un rôle crucial en génétique moléculaire : ils facilitent l'alignement, la mise en correspondance et l'analyse des séquences dérivées de nouveaux échantillons. GRCh38, qui est le plus couramment utilisé jusqu'à présent, a été élaboré à partir d'un échantillon restreint de donneurs, majoritairement d'origine européenne [25,1]. Cette décision initiale, bien que logique dans le cadre technologique des années 1990, a engendré une série de préjugés structurels qui subsistent actuellement dans une multitude de bases de données génétiques à l'échelle internationale.

Ces biais ne sont pas uniquement quantitatifs, ils sont également qualitatifs. On les voit clairement à différentes phases de production, d'analyse et d'utilisation des données génomiques. On peut identifier au moins six grandes catégories :

1.2.1. Biais de représentation

La majorité des séquences génétiques disponibles provient d'individus d'origine européenne. En 2016, plus de 80 % des participants aux GWAS étaient européens, contre moins de 3 % d'ascendance africaine ; en 2022, ce taux est tombé à 1,1 % [2,26]. Ce déséquilibre est d'autant plus problématique que l'Afrique abrite la plus grande diversité génétique humaine [1,15]. Les populations métissées, comme celles de La Réunion, sont largement absentes de ces référentiels [3,14].

1.2.2. Biais de fréquence

Les bases de référence surestiment la fréquence des variants présents dans les populations dominantes, ce qui peut conduire à mal classer comme “rares” des variants fréquents dans d'autres groupes, ou inversement. Ce phénomène peut entraîner des erreurs de diagnostic ou de filtrage lors des analyses cliniques [12,17,18].

1.2.3. Biais de structure

Les génomes de référence linéaires ne capturent qu'un seul haplotype pour chaque région, négligeant ainsi les variants structuraux (inversions, duplications, délétions) qui sont pourtant fréquents et significatifs dans d'autres populations. Les études de pan-génomes commencent à combler ce vide, mais leur intégration dans les pipelines de référence reste limitée [19].

1.2.4. Biais d'annotation

Les bases d'annotation fonctionnelle (par ex. Ensembl, ClinVar) reposent principalement sur des connaissances acquises à partir de cohortes européennes. Cela conduit à une sous-annotation des variants spécifiques à d'autres groupes, ou à une interprétation erronée de leur effet. De nombreux variants dits “de signification inconnue” (VUS) sont en réalité fréquents ou bénins dans les populations sous-représentées [27].

1.2.5. Biais d'accessibilité

Certains groupes n'ont pas eu un accès équitable aux technologies de séquençage, ni à la valorisation de leurs données. Cela crée une inégalité structurelle dans la production des connaissances génétiques. La majorité des projets de référence sont issus d'institutions du Nord global, avec peu de participation directe des pays du Sud [16].

1.2.6. Biais éthique

L'absence ou la faible inclusion de certaines populations ne soulève pas seulement des questions scientifiques, mais aussi éthiques. Lorsqu'une diversité génétique n'est pas prise en compte, cela peut limiter l'accès équitable aux bénéfices de la recherche. Cette situation, qualifiée d'injustice épistémique, renvoie à une inégale reconnaissance des besoins et apports de certaines populations dans les priorités scientifiques.

Les biais présents dans les génomes de référence ne sont ni anecdotiques ni purement techniques. Ils touchent toutes les étapes de la recherche et de l'interprétation génétique : de la collecte des données jusqu'à leur annotation et leur utilisation clinique. Ces biais qu'ils soient liés à la sous-représentation de certaines populations, à la fréquence ou à la structure des variants, à la qualité de l'annotation, à l'accessibilité technologique ou à des dimensions éthiques plus profondes compromettent la robustesse des analyses et l'équité des applications médicales.

Pour la Réunion, population marquée par une diversité génétique issue de multiples flux migratoires, ces limites sont préoccupantes. Elles justifient la mise en place d'un génome de référence local, capable de mieux représenter cette population, d'alimenter des outils de diagnostic fiables, et de garantir une accessibilité équitable aux bénéfices de la recherche génomique.

1.3. Conséquences cliniques, scientifiques et éthiques

L'absence de représentativité génétique dans les bases de données mondiales a des effets significatifs, surtout dans un contexte tel que celui de La Réunion. Ce manque affecte non seulement la qualité des traitements, mais aussi la crédibilité de la recherche et l'équité dans l'accès à l'innovation en matière de santé. L'intelligence artificielle, qui prend de l'ampleur dans l'analyse génétique et les prises de décision cliniques, pourrait exacerber ces disparités si elle repose sur des données non représentatives [3,28].

1.3.1. Sur le plan clinique

L'utilisation de bases de référence calibrées sur des populations européennes peut entraîner des erreurs d'interprétation des variants génétiques. Certains peuvent être mal classés ou ignorés, compromettant le diagnostic ou l'orientant vers un traitement inadapté [27,12]. Cela concerne notamment les traitements à marge étroite, comme les anticoagulants ou certains anticancéreux, où les mutations génétiques influencent fortement la réponse au traitement. Les outils d'aide à la décision, y compris ceux basés sur l'IA, ne font qu'amplifier ces biais s'ils ne tiennent pas compte de la diversité réelle des patients. À La Réunion, où la population est largement métissée, cette situation augmente le risque d'effets indésirables ou de perte de chance thérapeutique [30,31].

1.3.2. *Sur le plan scientifique*

Le manque de données représentatives limite la capacité à produire des résultats robustes et utiles localement. Les modèles d'analyse, les pipelines bioinformatiques et les algorithmes de prédiction sont souvent optimisés pour des profils génétiques homogènes [3]. Cela rend les études sur des populations comme celle de La Réunion plus difficiles à interpréter, moins comparables et parfois non publiables. L'intelligence artificielle, qui dépend fortement des données sur lesquelles elle s'entraîne, reproduit ces biais et peut exclure ou sous-évaluer les spécificités génétiques réunionnaises si elles ne sont pas intégrées dès l'amont [28,29].

1.3.3. *Sur le plan éthique*

L'inégalité d'accès aux bénéfices de la médecine génomique soulève une question de justice. Lorsque les référentiels utilisés ne reflètent qu'une fraction de la diversité humaine, les autres populations restent à la marge des avancées cliniques et technologiques [26]. Cela crée une situation où certaines populations comme celle de La Réunion sont plus exposées à l'erreur, moins bien servies par les algorithmes, et invisibles dans les grandes décisions de santé publique. L'utilisation croissante de l'IA en santé renforce ces enjeux : si elle est mal conçue, elle peut accentuer les écarts. Mais bien utilisée, elle pourrait au contraire devenir un levier de correction, en intégrant des profils génétiques variés et en proposant des analyses mieux adaptées [31,32].

1.4. Cas particulier de la population réunionnaise

La population réunionnaise se distingue par une richesse génétique unique, fruit d'une histoire migratoire complexe et d'un métissage continu entre des individus d'origines africaine, indienne, malgache, européenne et asiatique. Ce qui entraîne cependant des défis particuliers en matière de génétique médicale et de pharmacogénétique.

Les bases de données et les outils de comparaison utilisés en génomique ont été majoritairement développés à partir de populations européennes. Dans ce contexte, la séquence de référence actuellement utilisée ne tient pas compte de l'ensemble du profil génétique des Réunionnais [2, 3, 15, 26]. Cela entraîne une diminution de la fiabilité des diagnostics génétiques, pharmacogénétiques et de la capacité à identifier des mutations spécifiques ou des facteurs de susceptibilité propres à cette population.

À cela s'ajoute un contexte génétique particulier lié au peuplement de l'île, tel que des effets fondateurs, des maladies rares isolées et l'influence du métissage sur l'expression des variants. Il est crucial d'avoir une méthode plus ciblée pour l'analyse de son génome, afin d'optimiser les outils de diagnostic et d'assurer un traitement médical approprié et plus juste.

Cette section cherche à illustrer, en s'appuyant sur des exemples spécifiques, que la population de La Réunion représente une exception dans la représentativité génétique. Elle étaye la mise en place d'un projet de génome de référence local.

1.4.1. *Histoire migratoire et métissage*

⇒ **Un peuplement sans autochtones et des migrations successives**

L'histoire démographique de l'île de La Réunion présente une singularité rare dans le monde : son peuplement s'est fait exclusivement par immigration, l'île étant inhabitée au moment de sa prise de possession par la France en 1642, puis réellement colonisée à partir de 1663 par des colons envoyés par la Compagnie des Indes orientales. Dès lors, la population de l'île s'est constituée par apports successifs, mêlant des origines européennes, africaines, malgaches, indiennes, chinoises, puis comoriennes et sud-est asiatiques au fil des siècles ^[34, 35].

L'absence de population autochtone a permis une recomposition intégrale des structures sociales et identitaires, à partir d'éléments importés. Ce phénomène a fait dire à l'historien Prosper Ève que La Réunion constitue un véritable "laboratoire d'histoire humaine", où les identités transplantées ont été contraintes de se reconfigurer dans un espace clos, insulaire, et sous domination coloniale :

« La Réunion est un laboratoire d'histoire humaine, un monde recomposé où se mêlent les fragments d'identités transplantées. » ^[34]

Les premiers colons sont principalement des Français pauvres originaires de l'Ouest du royaume, auxquels s'ajoutent quelques engagés européens. Mais la croissance économique (notamment la culture de la canne à sucre) va rapidement imposer une exploitation intensive, qui repose sur le recours massif à l'esclavage. À partir de la fin du XVII^e siècle et surtout au XVIII^e, ce sont des milliers d'esclaves, principalement originaires de Madagascar (Betsimisaraka, Sakalava, Antandroy) et d'Afrique de l'Est (Mozambique, région swahilie), qui sont déportés vers l'île ^[36]. On estime que plus de 160 000 esclaves ont transité par l'île avant l'abolition de 1848 ^[35].

Ces esclaves apportent avec eux leurs langues, leurs religions, leurs pratiques culturelles et sociales. Ils sont souvent regroupés de force sur les habitations sucrières, dans des conditions particulièrement dures, et soumis à une logique de dépersonnalisation et de domination. Pourtant, malgré cette entreprise de déstructuration culturelle, des formes de résistance s'élaborent : créolisation linguistique, pratiques religieuses syncrétiques, et surtout marronnage, qui consiste à fuir dans les hauteurs de l'île et y reconstituer une vie autonome, parfois avec d'autres esclaves, parfois même avec des Blancs pauvres ou des engagés en rupture.

La pluralité des origines et l'absence d'un groupe autochtone dominant, du fait d'une présence humaine relativement récente, vont favoriser une hybridation progressive des identités dès les premières générations nées sur l'île, ce qui va contribuer à l'édification de la future société créole réunionnaise. Cette dynamique sera renforcée au XIX^e siècle avec l'engagisme.

⇒ **L'esclavage et les résistances**

L'esclavage à La Réunion a structuré toute l'économie coloniale jusqu'en 1848, générant un système de violence et de déshumanisation. Face à cette oppression, les

esclaves n'étaient pas passifs : ils résistèrent, souvent au péril de leur vie. Le marronnage en fut l'expression la plus spectaculaire. Fuyant les plantations, ces esclaves fondaient dans les cirques de Salazie ou de Cilaos de véritables micro-sociétés clandestines, hors du contrôle des maîtres.

« Le marron est l'homme de la rupture ; il rejette le monde colonial et tente d'en bâtir un autre dans les hauteurs. » (Sudel Fuma, La révolte des oreilles coupées, 2011)

L'insurrection de 1811, surnommée « la révolte des oreilles coupées », illustre cette volonté collective de briser les chaînes et de renverser l'ordre colonial.

Mais la résistance ne se limitait pas à la fuite. Elle s'exprimait aussi dans le quotidien par des gestes discrets : ralentir le travail, saboter des outils, préserver des rituels culturels et spirituels transmis en secret. Ces formes silencieuses de résistance ont permis l'émergence d'une culture créole unique.

« Une infinité de petits gestes de résistance, silencieux, mais lourds de sens, ont permis aux esclaves de ne pas céder totalement. » (Prosper Ève, Le bruit du silence, 2010)

Ainsi, dans l'ombre des habitations coloniales, se transmettait une mémoire venue d'Afrique et de Madagascar, portée par les langues, les prières, les chants et les pratiques médicinales.

Les traces matérielles de cette résistance existent toujours. En 2006, des fouilles à Saint-Paul ont mis au jour un ancien cimetière d'esclaves. Certaines sépultures montraient des mutilations dentaires rituelles, caractéristiques de certaines cultures d'Afrique de l'Est. Ces rites, maintenus malgré les interdits, témoignent d'une résistance culturelle à travers la mort.

« Ces sépultures sont les témoins d'une fidélité culturelle inextinguible, même dans le silence de la terre. » (Sudel Fuma & Prosper Ève, rapport de fouilles, 2006)

Enfin, pour contenir ces résistances, la colonie a mis en place une répression judiciaire féroce. Les procès servaient davantage à terroriser qu'à rendre justice. L'exemple du commandant Morette, jugé pour violences extrêmes, en est une illustration glaçante.

« Le droit colonial se voulait dissuasif, punitif, et non réparateur. Il garantissait la peur comme mode de gouvernement. » (Gérard & Grimaud, Des esclaves sous le fouet, 2016)

Ces mécanismes de discipline illustraient la volonté du système colonial de briser toute velléité d'émancipation.

⇒ **L'engagisme : une migration contractuelle mais contrainte**

Après l'abolition de l'esclavage en 1848, les grands propriétaires sucriers de La Réunion doivent faire face à une crise sans précédent : la libération de près de 60 000 esclaves engendre une pénurie brutale de main-d'œuvre. Pour y remédier, les colons mettent en place un système d'engagisme, censé reposer sur le volontariat contractuel, mais qui, dans la pratique, prend souvent la forme d'une migration encadrée, déséquilibrée, et parfois coercitive.

« L'engagé ne succède pas à l'esclave, il en prolonge la figure dans une autre forme de dépendance, désormais légale. » (Prosper Ève, *Engagisme et société coloniale*, 2006 ^[37])

Entre 1848 et les années 1930, plus de 200 000 engagés sont introduits à La Réunion. La majorité provient du sud de l'Inde (notamment des Tamouls), mais d'autres viennent de Chine, d'Afrique de l'Est, de Madagascar, des Comores et même d'Asie du Sud-Est. Ces hommes (et plus rarement des femmes) signent des contrats de 5 ans renouvelables, parfois sans en comprendre les termes, traduits approximativement, voire jamais expliqués.

« L'engagement était un contrat que l'on ne lisait pas. Il reposait souvent sur la tromperie ou sur l'ignorance des parties. » (Michèle Marimoutou, *L'Indien de La Réunion : culture, religion, identité*, 2002 ^[39])

À leur arrivée sur l'île, les engagés sont affectés aux plantations dans des conditions proches de celles de l'esclavage. Certains chercheurs, comme Sudel Fuma, évoquent une forme de "servitude déguisée", dans laquelle le statut juridique évolue, mais les conditions de vie et la dépendance restent quasi identiques.

Par ailleurs, les pratiques médicales, religieuses ou funéraires des engagés sont souvent vues comme suspectes ou « exotiques » par l'administration coloniale, qui tente parfois de les réguler, voire de les interdire. Malgré cela, ces groupes conservent des pans entiers de leur culture d'origine. Temples tamouls, pagodes chinoises et cultes syncrétiques voient le jour dans plusieurs communes de l'île.

« L'espace insulaire a contraint à l'invention : l'Indien engagé devient créole, sans perdre ses dieux ni sa langue, mais en les métissant. » (Jean-Régis Ramsamy, *Les noms tamouls à La Réunion*, 2007 ^[41])

L'engagisme contribue ainsi à la créolisation sociale et culturelle de La Réunion. Ces travailleurs, initialement perçus comme « importés », s'enracinent sur l'île, fondent des familles, transmettent des langues, des musiques, des cuisines et des croyances. Ils participent pleinement à la construction d'une société réunionnaise pluriethnique, traversée de multiples héritages.

Cependant, leur mémoire est longtemps restée silencieuse, marginale, souvent cantonnée à une histoire "moins noble" que celle des esclaves. Ce n'est qu'à partir des années 1980–2000 que les descendants d'engagés ont commencé à réhabiliter cette mémoire dans l'espace public (journées tamoules, commémorations du 6 novembre, musées de l'engagisme). ^[37, 38, 39, 40, 41]

« Le silence des engagés fut longtemps celui de l'humilité et de l'effacement. Mais il est devenu une parole retrouvée, affirmée, revendiquée. » (Prosper Ève, *colloque de l'Université de La Réunion*, 2012 ^[38])

⇒ *Une société métissée, linguistique, culturelle et biologique*

Le métissage à La Réunion ne fut pas un simple phénomène biologique ou démographique. Il constitue l'un des fondements mêmes de l'identité réunionnaise, en s'exprimant à la fois dans les corps, les langues, les cultures, les religions et les pratiques sociales. La rencontre de populations aux origines multiples (africaines,

malgaches, européennes, indiennes, chinoises, comoriennes) a produit un tissu social inédit dans l’océan Indien.

« À La Réunion, le métissage est plus qu’un croisement biologique : il est une dynamique permanente de recomposition des signes, des récits et des pratiques. » Jean-Régis Ramsamy, *Les noms tamouls à La Réunion*, 2007^[41]

Sur le plan linguistique, le créole réunionnais incarne cette hybridation. Langue de contact née dans les champs de canne et les cases d’habitation, il mêle structures grammaticales africaines et vocabulaire majoritairement français, avec des apports malgaches, tamouls, voire portugais. Il est devenu l’un des vecteurs les plus puissants de la culture insulaire.

Sur le plan religieux, la cohabitation des cultes est remarquable. On trouve sur un même territoire des églises catholiques, des temples tamouls, des pagodes chinoises, des mosquées et des autels syncrétiques. Prosper Ève souligne que cette pluralité ne repose pas sur une simple juxtaposition, mais bien sur une logique de créolisation spirituelle.

« Le Réunionnais est souvent catholique par baptême, hindou par tradition, musulman par respect, animiste par mémoire. Il vit dans un pluralisme assumé. » Prosper Ève, colloque “ Croyances et métissage”, 2013^[43]

Les rituels sont fréquemment partagés ou hybridés. On peut, par exemple, voir des Réunionnais de toutes confessions participer aux marches sur le feu (*marche soulamon*) organisées par les Malbars, ou encore visiter les temples chinois lors du Nouvel An lunaire. Cette souplesse rituelle reflète un profond métissage des mentalités.

Le métissage s’observe aussi dans les pratiques culinaires (cari, samoussas, bonbons piments, rougails chinois...), les musiques (maloya, séga, musiques indiennes ou africaines remixées localement), ou les systèmes de parenté, où les prénoms, noms et lignées combinent plusieurs héritages.

Enfin, ce métissage n’est pas que culturel : il est aussi biologique, et cela constitue un point crucial du projet génomique. L’hétérogénéité des origines a donné naissance à une population fortement admixtée, avec des profils génétiques uniques. Cette réalité doit être mieux étudiée et représentée dans les références génomiques.

« Le Réunionnais n’a pas un patrimoine génétique pur, mais une généalogie composite, traversée de lignées multiples. Ce mélange n’est pas un déficit, mais une richesse. » Michèle Marimoutou, *Créolisation et mémoire*, 2001^[42]

Pourtant, cette complexité a longtemps été perçue par les institutions comme une difficulté à gérer ou une menace pour la stabilité sociale. Ce n’est qu’à partir des années 1990 que le métissage est devenu un objet de fierté identitaire et un levier de revendication culturelle dans les politiques locales.

« Pendant longtemps, on a nié le métissage. Aujourd’hui, on le revendique comme un moteur de la Réunion. C’est une révolution tranquille. » Sudel Fuma, *conférence publique*, 2010^[44]

La population réunionnaise est le fruit d'un peuplement intégralement issu de migrations, sans population autochtone préexistante. Depuis la colonisation française du XVII^e siècle, l'île a vu converger une mosaïque humaine sans équivalent : esclaves africains et malgaches, colons européens, engagés indiens, chinois, comoriens ou encore sud-est asiatiques. Ce brassage, souvent contraint, parfois choisi, s'est structuré dans le cadre d'un ordre colonial marqué par l'exploitation, la hiérarchie raciale et la dépendance.

L'esclavage, puis l'engagisme, ont été les deux principaux cadres d'arrivée des populations non européennes. Le marronnage, les résistances quotidiennes, les formes de transmission clandestine ou rituelle ont cependant permis à ces groupes de préserver leurs héritages, tout en inventant un nouveau langage commun : celui du métissage. Le créole, les pratiques religieuses syncrétiques, la cuisine, les musiques et les rites funéraires incarnent cette dynamique permanente d'hybridation et de recomposition culturelle.

Ce métissage n'est pas seulement social ou symbolique : il est aussi biologique. À travers les unions interethniques sur plusieurs générations, les Réunionnais ont hérité d'une diversité génétique exceptionnelle, façonnée par des apports multiples et une relative fermeture insulaire. Cette hétérogénéité génétique, profondément enracinée dans l'histoire migratoire de l'île, constitue aujourd'hui un enjeu central pour la médecine personnalisée.

C'est précisément cette singularité génétique, façonnée par les flux migratoires passés, qui explique la prévalence de certaines pathologies à effet fondateur au sein de la population réunionnaise.

1.4.2. *Prévalence de pathologies à effet fondateur*

En génétique des populations, une population dite **panmictique** est un modèle théorique dans lequel tous les individus peuvent potentiellement se reproduire entre eux, sans contraintes géographiques, sociales ou génétiques. Cette situation, couplée à une taille infinie, sous-tend l'équilibre de Hardy-Weinberg, où les fréquences alléliques et génotypiques se stabilisent en l'absence de forces évolutives externes (mutation, migration, sélection, dérive) ^[45,46].

Cependant, lorsqu'un petit sous-groupe d'individus issus d'une population panmictique se détache pour en fonder une nouvelle, il emporte avec lui une fraction limitée du patrimoine génétique d'origine, de manière purement aléatoire. Ce phénomène est appelé **effet fondateur**. En raison de la taille réduite de ce groupe fondateur, certaines variantes rares peuvent être surreprésentées, perdues ou fixées dans la descendance. Ce processus constitue un cas extrême de dérive génétique ^[47].

Mathématiquement, dans une population de taille effective N_e , la variance de la fréquence allélique d'un allèle neutre suit :

$$\text{Var}(p_{t+1}) = \frac{p_t(1 - p_t)}{2N_e}$$

Où P_t est la fréquence de l'allèle à la génération t . En cas d'effet fondateur, la chute brutale de N_e entraîne une forte instabilité des fréquences alléliques d'une génération à l'autre, menant à une perte d'hétérozygotie et à une structure génétique déséquilibrée [48, 49, 50].

Sur le plan chromosomique, cette structure se révèle par un **déséquilibre de liaison (LD)** élevé entre loci proches, mesuré par les paramètres :

- $D = f_{AB} - f_A \cdot f_B$ où f_{AB} est la fréquence de l'haplotype observé ;
- $r^2 = \frac{D^2}{f_A(1-f_A) \cdot f_B(1-f_B)}$, qui donne la corrélation standardisée entre deux loci.

Dans une population panmictique à grand effectif, la recombinaison efface progressivement le déséquilibre de liaison, sauf en cas de sélection ou d'isolement génétique. En revanche, dans une population fondée par un petit nombre d'individus, le déséquilibre de liaison est souvent maintenu artificiellement élevé, en raison de la co-transmission fréquente de certains haplotypes initiaux. Ce phénomène est particulièrement utile pour l'identification de **segments d'autozygotie** ou de régions génomiques enrichies en variants délétères.

Ainsi, l'effet fondateur induit :

- Une réduction de la diversité allélique globale ;
- Une structuration non aléatoire du génome par dérive et isolement ;
- Une augmentation artificielle de la LD dans certaines régions chromosomiques ;
- Une prévalence locale de maladies autosomiques récessives, surtout si les allèles pathogènes ont été portés par les fondateurs initiaux.

Ces caractéristiques sont particulièrement marquées dans les populations insulaires, endogames ou ayant connu des goulots d'étranglement démographiques sévères.

L'histoire démographique de La Réunion remplit plusieurs conditions clés favorisant l'émergence d'effets fondateurs : peuplement tardif (à partir du XVII^e siècle), population fondatrice numériquement réduite, isolement insulaire, et flux migratoires successifs mais souvent cloisonnés dans des groupes sociaux, ethniques ou religieux peu interconnectés sur le plan reproductif. En génétique des populations, un tel contexte constitue un terreau idéal pour l'apparition de déséquilibres génétiques durables. [51, 52, 53]

Le peuplement initial de l'île s'est effectué sans population autochtone, à partir de colons européens (principalement français), d'esclaves originaires d'Afrique de l'Est et de Madagascar, puis d'engagés indiens, chinois et comoriens. Ces populations, bien que culturellement mélangées à long terme, sont arrivées par vagues successives, souvent en

nombre réduit et avec peu de brassage immédiat. De nombreuses lignées familiales actuelles sont ainsi issues de fondateurs génétiques isolés, dont les profils ont été transmis de génération en génération avec peu de renouvellement extérieur, notamment dans certaines régions rurales de l'île.

Cette configuration a plusieurs conséquences génétiques mesurables :

- Des régions d'homozygotie étendues (ROH – *runs of homozygosity*) sont détectables chez une proportion significative d'individus réunionnais, notamment dans les zones reculées ou historiquement moins métissées.^[54]
- Des mutations pathogènes autosomiques récessives sont retrouvées à des fréquences disproportionnées, dans plusieurs maladies rares spécifiques à l'île, alors qu'elles sont quasi absentes des bases de données internationales.^[51, 52, 53]
- Le déséquilibre de liaison local est souvent élevé, facilitant la cartographie génétique des segments transmis par autozygotie.^[54, 55]
- Certains allèles délétères présents à l'origine à des fréquences très faibles dans les populations africaines, malgaches ou européennes sont devenus quasi endémiques à La Réunion, par transmission fondatrice.

Par ailleurs, la pratique de l'endogamie partielle, liée à l'insularité et à certaines contraintes géographiques, religieuses ou sociales, a permis la perpétuation de segments génomiques hérités des fondateurs, sans recombinaison externe^[54, 55]. Cette situation se distingue d'autres populations ultramarines par le niveau élevé d'admixture ethnique observé sur plusieurs générations, qui coexiste paradoxalement avec des foyers d'homogénéité génétique locale.

Cette hétérogénéité à la fois admixtée globalement et fondatrice localement rend la population réunionnaise particulièrement intéressante pour les études de génétique médicale. Elle pose cependant un défi majeur : les outils de diagnostic génétique standards, conçus sur des populations européennes ou est-asiatiques, échouent souvent à interpréter correctement les profils réunionnais. D'où l'intérêt de développer un référentiel génomique local^[55].

Cette complexité remet moins en cause les outils eux-mêmes que leur usage standardisé, qui reste inadapté en l'absence d'une base de référence locale.

1.4.3. *Inadaptation des outils génétiques actuels*

Les outils d'analyse génétique actuellement utilisés en routine, outils d'annotation (VEP, ANNOVAR), bases de fréquence (gnomAD, ExAC), prédicteurs de pathogénicité (CADD, SIFT, PolyPhen), ou plateformes d'interprétation (Varsome, Franklin) reposent majoritairement sur des données issues de populations à ascendance européenne ou est-asiatique. Leur utilisation sur la population réunionnaise, métissée et fondatrice, peut induire plusieurs biais :

- De **faux positifs** : variants fréquents localement mais considérés comme rares selon les référentiels standard.

- De **faux négatifs** : variants pathogènes réellement significatifs dans la population locale mais invisibles faute de présence dans les bases globales.
- Une **sous-estimation des régions autozygotes** ou de l'importance du déséquilibre de liaison.
- Une **interprétation erronée des scores de pathogénicité**, qui ne tiennent pas compte de la structure génomique spécifique de La Réunion.

Ces limites sont documentées dans la littérature. En particulier, plusieurs études ont mis en évidence que la sous-représentation de populations diverses dans les bases comme gnomAD génère une incertitude diagnostique significative [2][29], dégrade la performance des prédicteurs chez les personnes d'ascendance africaine [56], et rend les scores inadaptés aux groupes insulaires et admixés [57][28].

Un enjeu majeur réside donc dans le recalibrage des outils existants par l'intégration d'une base de fréquence locale. Celle-ci permettrait de :

- Ajuster les seuils de filtrage (ex. : fréquences dans VEP/ANNOVAR),
- Reparamétriser les scores de sévérité (CADD, REVEL) en tenant compte de l'admixture,
- Adapter les critères d'interprétation (ACMG) aux spécificités réunionnaises.

L'objectif du projet génome Réunion est précisément de créer cette base de référence locale, afin de standardiser une utilisation plus fiable et équitable des outils génétiques. Au lieu de réinventer la roue, il s'agit d'en changer la jante, pour que les outils s'adaptent aux réalités démographiques de La Réunion.

2. Problématique et justification du projet

L'introduction de ce document a mis en lumière plusieurs constats fondamentaux concernant la population réunionnaise sur le plan génétique. D'une part, cette population se caractérise par une double singularité : un fort degré d'admixture multi-continental (africain, malgache, européen, indien, asiatique), et la présence d'effets fondateurs régionaux, résultant de vagues migratoires successives, partiellement isolées [51, 52, 55]. D'autre part, les bases de données génomiques actuelles (comme gnomAD ou ExAC) sont largement construites à partir de données issues de populations européennes et est-asiatiques, ce qui aboutit à une sous-représentation sévère des profils réunionnais [2, 19].

Cette situation engendre plusieurs difficultés pratiques :

- Des erreurs dans l'annotation ou la classification de variants pathogènes ou bénins [56] ;
- Des faux positifs et négatifs dans le diagnostic de maladies génétiques rares [58] ;
- Une iniquité dans l'accès aux outils de médecine personnalisée, notamment en pharmacogénétique [59].

Or, comme l'ont souligné plusieurs études récentes, l'absence de diversité dans les référentiels génétiques mondiaux compromet non seulement la validité scientifique des analyses, mais aggrave également les inégalités de santé dans les populations sous-représentées [2, 59].

Dans le cas de La Réunion, les spécificités génétiques locales, couplées à des pratiques d'endogamie partielle, à un isolement insulaire, et à une histoire migratoire unique, font de cette population un cas d'étude exemplaire pour démontrer la nécessité d'un référentiel génomique régional [51, 52, 54, 55].

Il s'agit donc non seulement de documenter une diversité biologique encore largement invisible dans les bases internationales, mais aussi d'ajuster les outils bioinformatiques existants pour qu'ils soient interprétables dans ce contexte particulier. Ce double objectif constitue la base scientifique et clinique du présent projet.

Nous commencerons par examiner, dans la section suivante, les limites des séquences de référence actuelles dans le cadre de l'analyse de données génétiques réunionnaises.

2.1. Limites des séquences de référence actuelles pour La Réunion

La sous-représentation des populations génétiquement admixées dans les bases de données génomiques mondiales a des conséquences méthodologiques majeures pour l'analyse des données issues de la population réunionnaise. Cette situation, déjà mise en lumière dans la section précédente, se manifeste de manière concrète dans l'utilisation des outils actuels de bioinformatique, d'annotation et de prédiction des effets des variants.

Les principales ressources de référence telles que *gnomAD*, *1000 Genomes Project* ou le *Human Pangenome Reference Consortium* ne contiennent aucun sous-groupe reflétant la complexité génétique de La Réunion. Les panels dits "diversifiés" n'incluent pas de

combinaison ancestrale comparable à celle observée sur l'île, et ne tiennent pas compte de la structuration locale des lignées. En conséquence, les outils développés à partir de ces bases peuvent produire des biais significatifs.

Sur le plan bioinformatique, les panels d'imputation génétique utilisés pour prédire les génotypes manquants sont calibrés sur des haplotypes absents des populations métissées de l'océan Indien. Leur performance est donc fortement diminuée à La Réunion. De même, les outils d'annotation fonctionnelle comme VEP ou ANNOVAR s'appuient sur des bases de fréquence de variants dominées par des profils européens et est-asiatiques. Les conséquences sont connues : des variants fréquents localement sont étiquetés comme « rares » voire « inconnus », et à l'inverse, certains variants potentiellement pathogènes sont faussement neutralisés car mal classifiés. Les scores prédictifs comme CADD, REVEL ou PolyPhen, ainsi que les filtres ACMG, appliquent des seuils universels qui ne tiennent aucun compte des spécificités des populations admixées [59, 19].

Ces biais ne sont pas uniquement théoriques. À La Réunion, des pathologies génétiques à forte prévalence locale illustrent clairement les lacunes des outils standard. Le *syndrome Larsen-Bourbon*, par exemple, est une forme rare de dysplasie osseuse associée à une mutation fondatrice du gène *B4GALT7*, identifiée exclusivement dans des familles réunionnaises [51, 52]. De même, le *syndrome de Ravine*, causé par une mutation dans un élément transposable exprimé en ARN non codant, n'a été décrit que chez des nourrissons de l'île [53]. Ces deux maladies étaient absentes des grandes bases de données génétiques mondiales.

Ce constat n'est pas propre à La Réunion. Plusieurs études menées dans des populations fortement admixées ont montré que l'ajout de panels de référence locaux améliore significativement la qualité des analyses génétiques. Au Brésil, des travaux récents ont révélé plusieurs millions de variants absents de gnomAD, et ont montré que les scores de risque génétique polygénique étaient faussés sans recalibrage local [60, 61]. Au Mexique, Martínez-Magaña et al. (2020) [62] ont identifié sept clusters d'admixture dans une population mestizo. Ces sous-populations, généralement invisibles avec les outils standards, présentent des fréquences très différentes de variants pharmacogénétiques considérées comme "actionnables". Cela démontre que la structure d'admixture fine peut influencer directement la pertinence des recommandations médicamenteuses, et qu'un panel global, homogénéisant toute la population, risque de masquer des signaux cliniques pertinents.

Ces exemples illustrent l'enjeu central : tant que la diversité génétique locale n'est pas prise en compte dès la conception des outils et des bases de données, les biais initiaux persistent dans toutes les étapes de l'analyse. Dans une population aussi génétiquement singulière que celle de La Réunion marquée à la fois par une richesse d'ascendances et par des effets fondateurs locaux cette situation engendre des pertes de chance diagnostiques et thérapeutiques, et alimente les inégalités de santé.

2.2. Inégalités d'accès aux traitements, biais diagnostiques

Les promesses de la médecine génomique reposent sur l'identification de variants génétiques pour affiner les diagnostics et personnaliser les traitements. Cependant, lorsque les données génétiques et les outils bioinformatiques sont biaisés en faveur de certaines populations, des inégalités concrètes apparaissent dans l'accès à un diagnostic fiable et à des traitements sûrs. Des études récentes mettent en évidence plusieurs formes de biais : des erreurs de classification de variants génétiques menant à de faux diagnostics dans des populations sous-représentées, des échecs thérapeutiques ou surdosages dus à des profils pharmacogénétiques mal pris en compte. Ces biais compromettent directement la médecine de précision, notamment pour des populations comme celle de La Réunion, en limitant la fiabilité des tests génétiques et la sécurité des traitements. Nous détaillons ci-dessous ces inégalités et leurs impacts concrets.

2.2.1 Biais Diagnostique

Un problème majeur provient de la sous-représentation de nombreuses origines ethniques dans les bases de données génomiques de référence (telles que les bases de fréquences alléliques ou de variants cliniques). Les variants génétiques rares dans les populations bien étudiées (souvent d'ascendance européenne) peuvent être erronément classés comme *pathogéniques* simplement parce qu'ils sont absents des bases de données alors même qu'ils peuvent être bénins et fréquents dans d'autres groupes ethniques. Des chercheurs ont montré que cela a conduit à de *faux positifs* en génétique médicale : par exemple, une étude sur la cardiomyopathie hypertrophique a révélé que plusieurs patients afro-américains avaient reçu un diagnostic génétique positif erroné, basé sur des variants identifiés comme pathogènes alors qu'ils étaient en réalité bénins. Ces variants avaient initialement été considérés comme causals de la maladie faute de données de fréquence dans des populations non-européennes, et ont ensuite été reclassifiés comme bénins une fois leur fréquence élevée mise en évidence chez les Afro-Américains. Les auteurs de cette étude ont estimé que l'inclusion ne serait-ce que d'un petit nombre d'individus d'ascendance africaine dans les cohortes de contrôle aurait probablement évité ces erreurs de classification ^[27].

Ce cas illustre comment l'absence de diversité dans les données de référence peut conduire à des *faux positifs diagnostiques*, avec des conséquences potentiellement graves : annonce erronée d'une prédisposition à une maladie génétique, inquiétude injustifiée pour les patients et leurs familles, voire traitements inappropriés.

De manière plus générale, les variants de signification incertaine (VUS, *variants of uncertain significance*) sont un résultat beaucoup plus fréquent lors de tests génétiques chez des patients d'ascendance non-européenne, en raison du manque de données comparatives pour ces populations. Une vaste étude portant sur 1,6 million de tests génétiques a montré que les patients asiatiques, africains ou hispaniques reçoivent significativement plus de variants « incertains » que les patients européens, ce qui ajoute une incertitude diagnostique et un stress supplémentaire pour ces populations. Cette disparité s'explique en partie par la sous-représentation historique de ces groupes dans la littérature médicale et les projets génomiques ^[63].

En d'autres termes, un patient de La Réunion ayant des origines mixtes africaines, malgaches, indiennes ou européennes pourrait se voir remettre un rapport génétique comportant de nombreux VUS simplement parce que les bases de données actuelles manquent de données sur son patrimoine génétique spécifique. Ces lacunes limitent la portée du diagnostic génétique pour ces patients : il est plus difficile de distinguer un variant réellement pathogène d'une simple variante bénigne propre à sa population d'origine. Cela peut mener soit à des surdiagnostics (lorsqu'un variant bénin est à tort attribué à une maladie), soit au contraire à des sous-diagnostics (lorsqu'un variant pathogène n'est pas reconnu comme tel, faute de données suffisantes). Dans tous les cas, l'absence de diversité dans les données génomiques de référence introduit un biais diagnostique défavorable aux populations sous-étudiées.

2.2.2 Inégalités d'accès aux traitements

L'hétérogénéité génétique entre populations ne concerne pas que les diagnostics, elle affecte aussi la réponse aux traitements médicamenteux. La pharmacogénétique étudie comment les variations génétiques modulent l'efficacité et la toxicité des médicaments. Or, si les recommandations posologiques et les essais cliniques ne tiennent pas compte de ces variations propres à chaque population, on risque des erreurs de dosage ou des échecs thérapeutiques pour certains groupes de patients.

Un exemple emblématique est celui de la **warfarine**, un anticoagulant dont la dose optimale varie fortement selon les individus en fonction de variants sur des gènes comme *CYP2C9* et *VKORC1*. Des algorithmes de dosage pharmacogénétique ont été développés pour personnaliser l'initiation du traitement, mais la plupart ont été calibrés sur des cohortes de patients européens ou asiatiques.

Des essais cliniques ont révélé que ces algorithmes amélioreraient la stabilité du traitement chez les patients d'ascendance européenne, mais pas chez les patients afro-américains. En pratique, cela signifie que, pour un patient d'ascendance africaine, un algorithme standard de dosage de la warfarine peut proposer une dose inappropriée, menant soit à un sous-dosage (et donc un risque de thrombose), soit à un surdosage (et un risque hémorragique). La raison principale est que certains variants influençant le métabolisme de la warfarine, fréquents chez les patients d'origine africaine, n'étaient pas inclus dans les modèles initiaux. Par exemple, des allèles comme *CYP2C9**5, *6, *8, *11, relativement rares chez les Européens mais plus courants en Afrique, modifient la sensibilité à la warfarine ; en ignorant ces variants, l'algorithme biaise ses prédictions. Ce constat a conduit à la révision des recommandations : depuis 2017, les lignes directrices intègrent la notion d'ascendance génétique dans la détermination de la dose de warfarine, et encouragent le développement d'algorithmes spécifiques pour les populations sous-représentées [30]. Ainsi, combler le manque de données pour les patients non-européens est essentiel afin d'éviter des erreurs thérapeutiques liées à un profil pharmacogénétique non pris en compte.

D'autres cas illustrent l'importance de considérer les différences interethniques dans le métabolisme des médicaments. Le **clopidogrel**, un antiagrégant plaquettaire, est métabolisé par l'enzyme *CYP2C19*. Une proportion significative de patients présente des variants de *CYP2C19* dits *loss-of-function* (perte de fonction) qui réduisent l'efficacité du clopidogrel en empêchant sa transformation en métabolite actif. Ces

variants (*CYP2C19**2 et *3 notamment) sont relativement peu fréquents chez les Européens, mais bien plus répandus chez les Asiatiques. Dans une cohorte de Grande-Bretagne regroupant des patients d'origine sud-asiatique, **57 %** des individus possédaient au moins un allèle *CYP2C19* de perte de fonction (impliquant qu'ils sont métaboliseurs *intermédiaires* ou *lents* du clopidogrel), alors qu'à peine 25 % de ces patients étaient des métaboliseurs dits "normaux".

En comparaison, chez les patients européens, la proportion de métaboliseurs normaux est bien plus élevée (environ 40–50 %) [64]. Ce décalage explique que dans les populations asiatiques, l'efficacité du clopidogrel soit moindre et le risque d'événements cardiovasculaires (comme la thrombose de stent) plus élevé en l'absence d'ajustement thérapeutique. Si l'on applique un traitement standard sans test génétique préalable dans une population où la moitié des patients ne métabolisent pas correctement le médicament, on s'expose à un taux d'échec thérapeutique important. Des autorités de santé et consortiums ont donc émis des recommandations pour adapter les antiagrégants en fonction du génotype *CYP2C19* (par exemple, utiliser un autre antiagrégant plaquettaire chez les porteurs de deux allèles défectueux). Là encore, la médecine personnalisée ne peut tenir ses promesses que si l'on connaît la distribution des variants pharmacogénétiques dans chaque population.

Il est frappant de constater que presque toutes les personnes, quel que soit leur groupe ethnique, portent au moins une variation génétique affectant le métabolisme d'un médicament : par exemple, une analyse récente a montré qu'environ 90 % des individus d'une cohorte latino-américaine (Colombie) possèdent au moins un variant pharmacogénétique "actionnable" c'est-à-dire ayant des implications cliniques en termes de dosage ou de choix du médicament. Cependant, la nature et la fréquence de ces variants varient d'une population à l'autre [65]. Si l'on extrapole les données d'un groupe (par exemple les Caucasiens) à un autre (par exemple les Réunionnais dont le patrimoine génétique est très diversifié), on risque donc de surdoser ou sous-doser certains patients, faute d'avoir identifié un variant pertinent chez eux. En somme, l'absence de prise en compte des profils génétiques variés entraîne des inégalités dans l'efficacité et la sécurité des traitements médicamenteux.

Les biais évoqués ci-dessus ont des conséquences très concrètes sur la pratique médicale dans des populations comme celle de La Réunion. Cette diversité génétique locale est très peu représentée dans les études génomiques internationales. En l'absence de données spécifiques à La Réunion, un variant potentiellement pathogène chez un patient réunionnais pourrait être mal interprété, faute de point de comparaison approprié. De même, un médicament prescrit selon des standards internationaux pourrait s'avérer moins efficace, ou plus toxique, pour certains patients réunionnais possédant des variants particuliers des enzymes métabolisant ce médicament.

L'impact de ces inégalités se manifeste de plusieurs façons en pratique. Sur le plan du diagnostic, un taux élevé de variants incertains ou de faux positifs peut conduire soit à des investigations complémentaires inutiles (anxiété, coûts accrus, cascades d'examen), soit à un retard diagnostic chez des patients réellement atteints (si un variant causal n'est pas reconnu comme pathogène immédiatement). Sur le plan thérapeutique, le risque iatrogène augmente lorsque les schémas posologiques ne sont pas adaptés au profil génétique du patient : par

exemple, un patient réunionnais ayant hérité d'un variant rare affectant une enzyme hépatique pourrait métaboliser trop lentement un médicament donné et souffrir d'effets secondaires graves, si le médecin n'a pas connaissance de ce profil atypique. Inversement, un traitement potentiellement très bénéfique pourrait être écarté à tort chez un patient, si un test génétique mal calibré indique à tort un risque élevé d'effet indésirable.

2.3. L'IA au service de la conception de médicaments : génomique, bases de données et biais de représentativité

L'intelligence artificielle (IA) devient de plus en plus importante dans la recherche et le développement (R&D) de nouveaux médicaments basés sur des données génomiques. Le développement d'un médicament est un processus long (dépassant souvent 10 ans) comportant une grande part d'incertitude : moins de 10 % des candidats sont capables d'être commercialisés avec succès, la majorité échouant en raison de problèmes d'efficacité ou de sécurité. Compte tenu de ces réalités, l'IA est perçue comme un avantage concurrentiel majeur pour améliorer l'accélération de la découverte de nouvelles cibles thérapeutiques prometteuses et renforcer les phases précliniques et cliniques de développement et de test en traitant d'énormes quantités de données biologiques bien au-delà des capacités des approches traditionnelles [66, 68]. Cependant, la performance de ces modèles dépend fortement de la qualité et de la représentativité des données utilisées, notamment des bases de données génomiques internationales, ce qui soulève la question des biais susceptibles d'en découler.

2.3.1 L'IA et l'identification des cibles thérapeutiques.

L'une des premières applications de l'IA dans la « drug discovery » concerne l'identification de nouvelles cibles thérapeutiques à partir des données génétiques et moléculaires. Les algorithmes de machine learning (ML) et deep learning (DL) sont particulièrement efficaces pour l'analyse de données multi-omiques (génomiques, transcriptomiques, protéomiques), permettant la détection de biomarqueurs et gènes clés associés à une maladie (examen de caractéristiques complexes, corrélations entre variantes, expression et protéome) [69]. Ces approches, en intégrant des données issues de différents niveaux biologiques, aident à prioriser des cibles prometteuses selon leur pertinence biologique et druggabilité [70, 66].

L'analyse des réseaux de gènes et protéines devient également plus performante avec l'IA. Des techniques comme les graph neural networks (GNN) se distinguent pour repérer des nœuds critiques dans des interactomes, correspondant à des cibles potentiellement thérapeutiques à cibler en priorité une tendance croissante dans le « AI-driven drug discovery » [71]. Par ailleurs, les modèles DL (réseaux neuronaux convolutionnels, convolutional et récurrents) sont utilisés pour prédire de nouvelles interactions médicament-cible à partir de données expérimentales ou issues de la littérature, ouvrant de nouveaux horizons thérapeutiques [72].

En plus de l'identification de cibles, l'IA générative via GAN, autoencodeurs variationnels (VAE) ou via « reinforcement learning » permet de créer et optimiser de nouvelles structures moléculaires répondant à des spécifications précises (biodisponibilité, affinité, stabilité) [10]. Par exemple, des plateformes comme Insilico Medicine utilisent des architectures combinant GAN et apprentissage renforcé pour générer des candidats-médicaments en quelques semaines seulement.

Un exemple emblématique de l'impact de l'IA est **AlphaFold2**, qui a généré plus de 200 millions de structures protéiques avec une précision atomique, dépassant de loin les structures résolues expérimentalement ^[73]. Des travaux récents montrent que combiner AlphaFold2 avec des méthodes de criblage moléculaire améliorées (*AF2-RAVE*) augmente considérablement le taux de succès des simulations *in silico* de liaison protéine-ligand ^[74]. Ces avancées renforcent l'utilisation de ces algorithmes pour évaluer la *druggabilité* des cibles bien avant les phases expérimentales.

2.3.2 IA et optimisation de l'efficacité des médicaments.

Au-delà de l'identification des cibles et de la conception de nouvelles molécules, l'IA intervient également dans le développement clinique et le suivi de l'efficacité des médicaments. Dans les essais cliniques, par exemple, elle peut aider à sélectionner les patients les plus adaptés (ceux qui ont les biomarqueurs génétiques indiquant qu'ils répondront au traitement), en exploitant les données des dossiers médicaux électroniques et les profils moléculaires pour un recrutement plus pertinent. L'IA sert aussi à améliorer le design des essais cliniques grâce à des modèles prédictifs qui optimisent les protocoles (doses, critères d'inclusion, etc.) et permettent des ajustements adaptatifs en cours d'étude. Des innovations récentes, comme les *bras de contrôle synthétiques* et les *jumeaux numériques* (*digital twins*), s'appuient sur l'IA pour *simuler* des résultats cliniques : par exemple, un jumeau numérique est une réplique virtuelle d'un patient ou d'une cohorte, dans laquelle on peut tester virtuellement l'efficacité d'un traitement. Ces simulations, alimentées par des données réelles de patients, offrent la possibilité de prédire l'efficacité et la tolérance d'un médicament sans exposer inutilement un grand nombre de personnes à des traitements expérimentaux, réduisant ainsi les risques et les coûts associés aux essais ^[66].

En phase de pharmacovigilance (après la mise sur le marché), l'IA peut analyser en continu les données du monde réel (retours cliniques, réseaux sociaux, registres de santé) pour détecter précocement des signaux d'efficacité ou d'inefficacité et ajuster les recommandations thérapeutiques. Par exemple, des algorithmes apprenants peuvent suggérer des ajustements posologiques en temps réel en fonction des réponses individuelles des patients, afin d'assurer une efficacité maximale tout en minimisant les effets secondaires illustrant le concept d'optimisation dynamique du traitement médicamenteux.

Enfin, l'IA contribue également à la découverte de nouvelles indications ou au repositionnement de médicaments existants. En combinant de vastes bases de connaissances (publications scientifiques, brevets, bases clinico-génomiques), des outils de traitement du langage naturel ou de fouille de graphes biomédicaux permettent d'établir des liens entre maladies, gènes et molécules thérapeutiques. Par exemple, plusieurs travaux ont utilisé ces techniques pour proposer rapidement des repositionnements de médicaments contre la COVID-19, à partir d'algorithmes intégrant des relations biomoléculaires et cliniques ^[77]. Ce type d'approche a montré que des molécules déjà connues pour d'autres indications (comme le baricitinib ou le remdesivir) pouvaient être priorisées en quelques jours via l'IA, là où la recherche classique aurait exigé des mois. Cette capacité à réutiliser des médicaments sûrs sur la base de prédictions algorithmiques fiables est désormais considérée comme l'un des leviers les plus puissants du développement pharmaceutique moderne.

2.3.3 IA, génomique et bases de données internationales.

Le succès de l'IA en génomique repose sur l'abondance des données disponibles. Ces dernières décennies, de grands projets internationaux tels que *The Cancer Genome Atlas* (TCGA), *All Of Us* ou le consortium *TARGET* sur les tumeurs pédiatriques ont constitué des bases de données génomiques colossales couvrant des milliers de patients à travers le monde [75]. Exploitées par l'IA, ces ressources permettent d'identifier des gènes associés à des maladies, de trouver de nouvelles cibles thérapeutiques et de progresser vers une médecine de précision fondée sur le profil moléculaire individuel des patients. Par exemple, en oncologie, l'analyse de vastes cohortes génétiques via des modèles d'IA a fait émerger des vulnérabilités spécifiques de certains cancers (mutations ou altérations génomiques *actionnables* par un traitement ciblé) qui n'auraient pas été évidentes autrement [76].

Cependant, un défi majeur réside dans la représentativité de ces bases de données internationales. Nous avons vu que les grandes banques de données génétiques actuelles ne reflètent pas fidèlement la diversité de la population mondiale [28]. Voici un autre exemple, où les individus d'ascendance européenne sont largement surreprésentés, tandis que les autres origines ancestrales sont sous-représentées. Dans la base de données des cancers TCGA la part de patients d'origine européenne s'élève à $\approx 82\text{--}83\%$, avec seulement environ 10% d'ascendance africaine, et des parts minimales d'Asie de l'Est, d'Asie du Sud, ou d'Amérindien [76]. De même, dans le GWAS Catalog, près de $90\text{--}95\%$ des participants sont d'ascendance européenne, tandis que les participants d'ascendance africaine continentale représentent moins de 1% du total [26]. À l'inverse, moins de 5% des données transcriptomiques disponibles proviennent de personnes d'ascendance africaine continentale, et seulement $\sim 2\%$ des génomes analysés dans les études internationales concernent cette population, malgré sa diversité génétique la plus vaste au monde [28].



Le déséquilibre eurocentré des données génomiques entraîne des biais dans les modèles d'IA appliqués à la santé. Concrètement, une IA entraînée majoritairement sur des données issues de patients d'origine européenne risque d'être moins performante pour

prédire des résultats ou identifier des cibles pertinentes chez des patients d'autres origines ethniques ou génétiques tel que les réunionnais.

2.4. Nécessité d'un génome de référence réunionnais

L'analyse des biais diagnostiques, thérapeutiques et scientifiques liés à l'absence de diversité dans les bases de données génétiques mondiales met en évidence une urgence concrète : celle de construire un référentiel génomique propre à La Réunion. Ce besoin dépasse la simple question de représentativité éthique. Il constitue une condition nécessaire à l'efficacité des outils de médecine personnalisée, à la fiabilité des analyses génétiques, ainsi qu'à l'équité en santé et en recherche pour les populations ultramarines.

Comme le montre les parties précédentes, la structure génétique de la population réunionnaise est marquée par une double singularité : d'un côté, une admixture ancienne, complexe et multicontinentale, incluant des ascendances africaine, malgache, indienne, européenne et asiatique ; de l'autre, des effets fondateurs régionaux résultant de vagues migratoires historiquement isolées, parfois entre croisées. Cette configuration génétique unique est absente de toutes les bases de données de référence internationales, y compris celles dites « diversifiées ».

En conséquence, les outils bioinformatiques standards qu'il s'agisse de filtres d'interprétation (comme les scores CADD, PolyPhen, REVEL), des panels d'imputation ou des modèles d'IA prédictifs produisent, dans le cas réunionnais, des résultats erronés, incomplets, voire injustes : faux positifs diagnostiques, variants mal classés, posologies inadaptées ou inefficacité médicamenteuse. Ces biais ne sont pas théoriques : ils ont déjà été documentés dans d'autres populations admixées ou sous-représentées, et se traduisent concrètement par des retards de diagnostic, des erreurs d'orientation thérapeutique ou des exclusions injustifiées des essais cliniques.

En outre, la montée en puissance des algorithmes d'intelligence artificielle dans la recherche biomédicale accentue encore ce besoin. Ces modèles reposent entièrement sur les bases de données existantes : si ces dernières sont biaisées, les prédictions le seront aussi. Cela affecte le développement de médicaments, la prédiction des effets secondaires, et l'évaluation des risques génétiques. Sans données représentatives de La Réunion, ces technologies resteront inopérantes ou potentiellement dangereuses pour cette population.

La création d'un génome de référence réunionnais, sera réalisé à partir d'un échantillonnage représentatif de la diversité génétique locale, permettrait de lever ces verrous. Il offrirait une base solide pour :

- Affiner l'interprétation des variants identifiés en séquençage ;
- Recalibrer les outils bioinformatiques et les scores prédictifs ;
- Améliorer la qualité des diagnostics génétiques et de la médecine personnalisée ;
- Garantir une meilleure inclusion des Réunionnais dans les projets de recherche internationaux.

Il ne s'agit donc pas d'un projet accessoire, ni d'un doublon vis-à-vis des initiatives globales : c'est une brique fondatrice d'une santé génomique équitable pour un territoire qui conjugue fort

métissage et singularité génétique. Ce génome réunionnais sera aussi un levier scientifique, permettant d'approfondir l'étude des pathologies locales rares (comme le syndrome Larsen-Bourbon ou le syndrome de Ravine), de mieux comprendre les trajectoires migratoires passées, et de contribuer activement à la science mondiale, non plus comme population "hors norme", mais comme référence en elle-même.

Domaine	Bénéfices attendus	Exemples concrets
Diagnostic génétique	Amélioration de l'interprétation des variants locaux Réduction des faux positifs/erreurs de diagnostic	Reclassification de VUS comme bénins/pathogènes Ciblage pour cardiomyopathies ou anomalies du métabolisme
Médecine personnalisée	Ajustement des posologies selon profils locaux Meilleure prédiction des effets secondaires	Warfarine (CYP2C9), clopidogrel (CYP2C19) Éviter sous-/surdosage selon les groupes
Santé publique	Surveillance des variants rares ou fondateurs Détection anticipée de risques populationnels	Syndrome Larsen-Bourbon, Ravine Segments autozygotes à risque par micro-régions
Recherche biomédicale	Référentiel unique pour effets fondateurs/admixture Représentativité dans les bases internationales	Interaction des composantes africaines, indiennes... Enrichissement de TOPMed, gnomAD, etc.
Développement pharmaceutique (IA)	Correction des biais dans les algorithmes IA Intégration de profils métissés dans les modèles	Cibles thérapeutiques prédictives fiables Recommandations plus justes des IA pharmacogénomiques
Justice et équité en santé	Réduction des inégalités d'accès au diagnostic	Inclusion dans essais cliniques internationaux Pilotage réunionnais

3. Objectif de l'étude

3.1. Objectif principal : création d'une base de variants spécifiques

L'île de La Réunion abrite une population métissée, provenant d'individus originaires d'Afrique, de Madagascar, d'Europe, d'Inde ainsi que d'Asie du Sud-Est. Cependant, cette diversité biologique est toujours largement manquante dans les bases de données génétiques à l'échelle internationale. Le projet Génome Réunion a pour but de pallier ce manque en réalisant le séquençage intégral du génome de plusieurs centaines d'habitants de la Réunion, choisis afin d'illustrer au mieux les différentes composantes génétiques présentes sur l'île.

L'objectif principal est de constituer une base de données de variants génétiques propres à La Réunion, comprenant polymorphismes fréquents, mutations rares et fréquences alléliques locales. Ce référentiel sera un outil de référence pour :

- Affiner les diagnostics médicaux,
- Éviter les erreurs d'interprétation,
- Adapter plus finement les traitements aux profils locaux.

D'un point de vue scientifique, cette base offre la possibilité d'examiner minutieusement des variants spécifiques associés aux lignées africaines, indiennes ou malgaches, qui sont fréquemment absents ou insuffisamment documentés dans les bases de données internationales. Elle offrira donc une nouvelle perspective sur les patrimoines génétiques spécifiques à la population de La Réunion, tout en participant à l'accroissement des connaissances relatives aux populations fortement métissées.

Ce travail s'inscrit également dans une vision régionale stratégique : en positionnant La Réunion comme un centre de référence en génomique dans l'espace sud-ouest de l'océan Indien, le projet ouvre la voie à des coopérations renforcées avec les pays voisins Madagascar, Comores, Maurice, Seychelles dans le cadre des initiatives soutenues par la **Commission de l'Océan Indien (CIO)**. Cette démarche scientifique devient ainsi un levier de développement régional, de diplomatie scientifique et de souveraineté sanitaire partagée.

Cette dynamique d'ouverture ne se limite pas au bassin régional. Par effet de retour d'ascendance, le projet ouvre également des perspectives de coopération scientifique avec les pays d'origine des composantes ancestrales réunionnaises, notamment en Afrique de l'Ouest et de l'Est, en Inde, en Chine ou en Europe du Sud. La base de données réunionnaise pourrait ainsi servir de référence comparative dans des analyses multicentriques sur les flux génétiques, les processus d'adaptation, ou les marqueurs de risque dans les populations métissées.

En parallèle, des collaborations internationales structurantes sont envisageables avec les grands programmes génomiques mondiaux, comme le **NIH** via l'initiative **H3Africa**, ou l'**European Genome-phenome Archive (EGA)**, afin d'intégrer la population réunionnaise dans les panels de diversité globale. À moyen terme, le projet pourrait positionner La Réunion comme un centre de formation régional francophone en génomique humaine, destiné à l'accueil de chercheurs d'Afrique de l'Est, de l'océan Indien et de pays partenaires dans une logique de renforcement de capacités, de science ouverte et de diplomatie sanitaire Sud-Sud.

Sur le plan médical, la base facilitera la distinction entre variants bénins fréquents à La Réunion et mutations réellement pathogènes, réduisant ainsi les risques de surdiagnostic, de traitements inadaptés ou d'incertitude génétique (VUS).

La base sera accessible aux partenaires scientifiques dans le cadre de conventions de collaboration encadrées (protection des données RGPD, HDS), favorisant :

- La mutualisation des outils et des expertises bioinformatiques,
- La conduite de projets multicentriques,
- La production de publications scientifiques collaboratives à fort impact.

Cette démarche élargira considérablement l'impact scientifique du projet, tout en garantissant la préservation et l'enrichissement du patrimoine génétique de La Réunion. Elle place La Réunion à la pointe des efforts mondiaux en faveur d'une génomique plus équitable, inclusive et enracinée dans les contextes régionaux.

3.2. Objectifs secondaires :

- 3.2.1. Étude de l'admixture
- 3.2.2. Impacts sur la pharmacogénétique
- 3.2.3. Valorisation épidémiologique et historique

Références bibliographiques

1. Mathias, R., Taub, M., Gignoux, C. *et al.* A continuum of admixture in the Western Hemisphere revealed by the African Diaspora genome. *Nat Commun* 7, 12522 (2016). <https://doi.org/10.1038/ncomms12522>
2. Popejoy AB, Fullerton SM. Genomics is failing on diversity. *Nature*. 2016 Oct 13;538(7624):161-164. doi: <https://doi.org/10.1038/538161a>. PMID: 27734877; PMCID: PMC5089703.
3. Bentley, A.R., Callier, S.L. & Rotimi, C.N. Evaluating the promise of inclusion of African ancestry populations in genomics. *npj Genom. Med.* 5, 5 (2020). <https://doi.org/10.1038/s41525-019-0111-x>
4. Agence Régionale de Santé de La Réunion. Survie des personnes atteintes de cancer à La Réunion 2008-2018 : étude de l'ARS. Disponible sur : <https://www.lareunion.ars.sante.fr/survie-des-personnes-atteintes-de-cancer-la-reunion-2008-2018>.
5. Zaroni F, Neugut YD, Obayemi JE, Gharavi AG, Keating B, Kiryluk K. Genetic versus self-reported African ancestry of therecipient and neighborhood predictors of kidney transplantation outcomes in 2 multiethnic urban cohorts. *J Clin Genet*. 2022.
6. Andaluz S, Zhao B, Sinha S, Lagniton PN, Costa DA, Ding X, et al. Using Portuguese BRCA pathogenic variation as a model to study the impact of human admixture on human health. *BMC Genomics*. 2024;24:10311. doi: [10.1186/s12864-024-10311-4](https://doi.org/10.1186/s12864-024-10311-4). PMID: 38671360; PMCID: PMC11055274.
7. Li K, Du Y, Li L, Wei DQ. Bioinformatics approaches for anti-cancer drug discovery. *Curr Drug Targets*. 2020;21(1):3-17. doi: [10.2174/1389450120666190923162203](https://doi.org/10.2174/1389450120666190923162203). PMID: 31549592.
8. Feng L, Zhu S, Ma J, Huang J, Hou X, Qiu Q, et al. Small molecule drug discovery for glioblastoma treatment based on bioinformatics and cheminformatics approaches. *Front Pharmacol*. 2024;15:1389440. doi: [10.3389/fphar.2024.1389440](https://doi.org/10.3389/fphar.2024.1389440). PMID: 38681202.
9. Finan C, Gaulton A, Kruger FA, Lumbers RT, Shah T, Engmann J, Galver L, Kelley R, Karlsson A, Santos R, Overington JP, Hingorani AD, Casas JP. The druggable genome and support for target identification and validation in drug development. *Sci Transl Med*. 2017 Mar 29;9(383):eaag1166. doi: 10.1126/scitranslmed.aag1166. PMID: 28356508; PMCID: PMC6321762.
10. Dhudum, R.; Ganeshpurkar, A.; Pawar, A. Revolutionizing Drug Discovery: A Comprehensive Review of AI Applications. *Drugs Drug Candidates* 2024, 3, 148-171. <https://doi.org/10.3390/ddc3010009>

11. Guy Doron, Sam Genway, Mark Roberts, Sai Jasti. New Horizons: Pioneering Pharmaceutical R&D with Generative AI from la to the clinic -- an industry perspective [\[arXiv:2312.12482](https://arxiv.org/abs/2312.12482) [q-bio.QM] <https://doi.org/10.48550/arXiv.2312.12482>
12. Martin AR, Gignoux CR, Walters RK, Wojcik GL, Neale BM, Gravel S, et al. Human demographic history impacts genetic risk prediction across diverse populations. *Am J Hum Genet.* 2017;100(4):635-49. doi: [10.1016/j.ajhg.2017.03.004](https://doi.org/10.1016/j.ajhg.2017.03.004). PMID: 28366442; PMCID: PMC5384097.
13. International Human Genome Sequencing Consortium. Finishing the euchromatic sequence of the human genome. *Nature.* 2004Oct 21;431(7011):931-45. doi: [10.1038/nature03001](https://doi.org/10.1038/nature03001). PMID: 15496913.
14. 1000 Genomes Project Consortium. A map of human genome variation from population-scale sequencing. *Nature.* 2010;467(7319):1061-73. doi: [10.1038/nature09534](https://doi.org/10.1038/nature09534).
15. Gurdasani D, Carstensen T, Tekola-Ayele F, et al. The African Genome Variation Project shapes medical genetics in Africa. *Nature.* 2015;517(7534):327-32. doi: [10.1038/nature13997](https://doi.org/10.1038/nature13997).
16. H3Africa Consortium, Rotimi C, et al. Research capacity: enabling the genomic revolution in Africa. *Science.* 2014;344(6190):1346-8. doi: [10.1126/science.1251546](https://doi.org/10.1126/science.1251546). PMID: 24948725; PMCID: PMC4138491.
17. ExAC project pins down rare gene variants. *Nature* **536**, 249 (2016). <https://doi.org/10.1038/536249a>
18. Lek M, Karczewski KJ, Minikel EV, et al. Analysis of protein-coding genetic variation in 60,706 humans. *Nature.* 2016;536(7616):285-91. doi: [10.1038/nature19057](https://doi.org/10.1038/nature19057).
19. Karczewski KJ, Francioli LC, Tiao G, et al.; Genome Aggregation Database Consortium. The mutational constraint spectrum quantified from variation in 141,456 humans. *Nature.* 2020 May;581(7809):434-443. doi:10.1038/s41586-020-2308-7. PMID:32461654.
20. Li Z, Jiang X, Fang M, Bai Y, Liu S, Huang S, Jin X. CMDB: the comprehensive population genome variation database of China. *Nucleic Acids Res.* 2023 Jan 6;51(D1):D890-D895. doi: [10.1093/nar/gkac638](https://doi.org/10.1093/nar/gkac638). PMID: 35871305; PMCID: PMC9825573.
21. Jung KS, Hong KW, Jo HY, Choi J, Ban HJ, Cho SB, Chung M. KRGDB: the large-scale variant database of 1722 Koreans based on whole genome sequencing. Database (Oxford). 2020 Jan 1;2020:baaa030. doi: [10.1093/database/baaa030](https://doi.org/10.1093/database/baaa030). Erratum for: Database (Oxford). 2020 Jan 1;2020:baz146. doi: [10.1093/database/baz146](https://doi.org/10.1093/database/baz146). PMID: 32348452; PMCID: PMC7190023.
22. Hwang MY, Choi NH, Won HH, Kim BJ, Kim YJ. Analyzing the Korean reference genome with meta-imputation increased the imputation accuracy and spectrum of rare variants in the Korean population. *Front Genet.* 2022 Nov 24;13:1008646. doi: [10.3389/fgene.2022.1008646](https://doi.org/10.3389/fgene.2022.1008646). PMID: 36506321; PMCID: PMC9731225.
23. The Indian Genome Variation Consortium. The Indian Genome Variation database (IGVdb): a project overview. *Hum Genet* **118**, 1-11 (2005). <https://doi.org/10.1007/s00439-005-0009-9>
24. Kodama Y, Mashima J, Kosuge T, et al. The DDBJ Japanese Genotype-phenotype Archive for genetic and phenotypic human data. *Nucleic Acids Res.* 2015;43(Database issue):D18-22. doi: [10.1093/nar/gku1120](https://doi.org/10.1093/nar/gku1120). PMID: 25477381; PMCID: PMC4383935.
25. International Human Genome Sequencing Consortium. Initial sequencing and analysis of the human genome. *Nature* **409**, 860-921 (2001). <https://doi.org/10.1038/35057062>.
26. Fatumo S, Chikowore T, Choudhury A, Ayub M, Martin AR, Kuchenbaecker K. A roadmap to increase diversity in genomic studies. *Nat Med.* 2022 Feb;28(2):243-250. doi: [10.1038/s41591-021-01672-4](https://doi.org/10.1038/s41591-021-01672-4). Epub 2022 Feb 10. PMID: 35145307; PMCID: PMC7614889.
27. Manrai AK, Funke BH, Rehm HL, Olesen MS, Maron BA, Szolovits P, Margulies DM, Loscalzo J, Kohane IS. Genetic Misdiagnoses and the Potential for Health Disparities. *N Engl J Med.* 2016 Aug 18;375(7):655-65. doi: [10.1056/NEJMsa1507092](https://doi.org/10.1056/NEJMsa1507092). PMID: 27532831; PMCID: PMC5292722.
28. Sirugo G, Williams SM, Tishkoff SA. The Missing Diversity in Human Genetic Studies. *Cell.* 2019 Mar 21;177(1):26-31. doi: [10.1016/j.cell.2019.02.048](https://doi.org/10.1016/j.cell.2019.02.048). Erratum in: *Cell.* 2019 May 2;177(4):1080. doi: [10.1016/j.cell.2019.04.032](https://doi.org/10.1016/j.cell.2019.04.032). PMID: 30901543; PMCID: PMC7380073.
29. Peterson RE and al. Genome-wide Association Studies in Ancestrally Diverse Populations: Opportunities, Methods, Pitfalls, and Recommendations. *Cell.* 2019 Oct 17;179(3):589-603. doi: [10.1016/j.cell.2019.08.051](https://doi.org/10.1016/j.cell.2019.08.051). Epub 2019 Oct 10. PMID: 31607513; PMCID: PMC6939869.
30. Perera MA and al. Genetic variants associated with warfarin dose in African-American individuals: a genome-wide association study. *Lancet.* 2013 Aug 31;382(9894):790-6. doi: [10.1016/S0140-6736\(13\)60681-9](https://doi.org/10.1016/S0140-6736(13)60681-9). Epub 2013 Jun 5. PMID: 23755828; PMCID: PMC3759580.
31. Johnson JA and al Clinical Pharmacogenetics Implementation Consortium (CPIC) Guideline for Pharmacogenetics-Guided Warfarin Dosing: 2017 Update. *Clin Pharmacol Ther.* 2017 Sep;102(3):397-404. doi: [10.1002/cpt.668](https://doi.org/10.1002/cpt.668). Epub 2017 Apr 4. PMID: 28198005; PMCID: PMC5546947.

32. Hasanzadeh F, Josephson CB, Waters G, Adedinsewo D, Azizi Z, White JA. Bias recognition and mitigation strategies in artificial intelligence healthcare applications. *NPJ Digit Med*. 2025 Mar 11;8(1):154. doi: 10.1038/s41746-025-01503-7. PMID: 40069303; PMCID: PMC11897215.
33. Paetznick C, Okoro O. The Intersection between Pharmacogenomics and Health Equity: A Case Example. *Pharmacy (Basel)*. 2023 Dec 5;11(6):186. doi: 10.3390/pharmacy11060186. PMID: 38133461; PMCID: PMC10747429.
34. Ève, P. (2003). *Esclavage, métissage, liberté : La Réunion, 1794–1848*. Paris : Karthala.
35. Fuma, S. (1992). *Esclavage et société à La Réunion (XVIIe–XIXe siècle)*. Saint-Denis : Azalées éditions.
36. Fuma, S. (1998). *Le marronnage à Bourbon*. Saint-Denis : Azalées éditions.
37. Ève, P. (2006). *Engagisme et société coloniale : regards sur l'histoire de La Réunion*. Presses Universitaires de La Réunion.
38. Ève, P. (2012). Intervention au colloque *Mémoires croisées de l'engagisme à La Réunion*, Université de La Réunion.
39. Marimoutou, M. (2002). *L'Indien de La Réunion : culture, religion, identité*. Mémoire de DEA, Université de La Réunion.
40. Fuma, S. (2010). *L'engagisme dans l'océan Indien, 1848–1920*. Saint-Denis : CRESOI / Azalées éditions.
41. Ramsamy, J.-R. (2007). *Les noms tamouls à La Réunion : mémoire, identité, transmission*. Saint-Denis : Azalées éditions.
42. Marimoutou, M. (2001). *Créolisation et mémoire dans l'océan Indien*. Mémoire de maîtrise, Université de La Réunion.
43. Ève, P. (2013). Intervention au colloque *Croyances et métissage à La Réunion*. Université de La Réunion.
44. Fuma, S. (2010). *Le métissage réunionnais : de la réalité historique à l'enjeu politique*. Conférence publique, Université populaire de La Réunion.
45. Chen, YS., Su, YC. & Pan, W. Effect of spatial constraints on Hardy-Weinberg equilibrium. *Sci Rep* 6, 19297 (2016). <https://doi.org/10.1038/srep19297>.
46. Hardy G. H. Mendelian proportions in a mixed population. *Science*. 1908 Jul 10;28(706):49–50. doi: 10.1126/science.28.706.49.
47. Wright, S. (1931). Evolution in Mendelian Populations. *Genetics*, 16(2), 97–159, doi: [10.1093/genetics/16.2.97](https://doi.org/10.1093/genetics/16.2.97).
48. Kimura, M. (1955). Random genetic drift in multi-allelic locus. *Evolution*, 9(4), 419–435. <https://doi.org/10.2307/2405656>
49. Kimura, M. (1983). *The Neutral Theory of Molecular Evolution*. Cambridge University Press. <https://doi.org/10.1017/CBO9780511623486>
50. Sònia Casillas, Antonio Barbadilla, Molecular Population Genetics, *Genetics*, Volume 205, Issue 3, 1 March 2017, Pages 1003–1035, <https://doi.org/10.1534/genetics.116.196493>
51. Cartault, F., Munier, P., Jacquemont, ML. *et al.* Expanding the clinical spectrum of *B4GALT7* deficiency: homozygous p.R270C mutation with founder effect causes Larsen of Reunion Island syndrome. *Eur J Hum Genet* 23, 49–53 (2015). <https://doi.org/10.1038/ejhg.2014.60>.
52. Alessandri JL, Celse T, Spodenkiewicz M, Calaya A, Dumont C, Jacquemont ML, Bertaut-Nativel B, Boumahni B, Rémy M, Ferroul F, Guilly S, Huby T, Irabé M, Laurens T, Munier P, Morel G, Payet F, Randrianaivo H, Doray B, Dospeux J. Prenatal and neonatal phenotype of Larsen of La Réunion Island syndrome (B4GALT7-linkeropathy). *Eur J Med Genet*. 2024 Jun;69:104940.doi: 10.1016/j.ejmg.2024.104940. Epub 2024 May 3. PMID: 38705458.
53. Cartault F, Munier P, Benko E, Desguerre I, Hanein S, Boddaert N, Bandiera S, Vellayoudom J, Krejbich-Trotot P, Bintner M, Hoarau JJ, Girard M, Génin E, de Lonlay P, Fourmaintraux A, Naville M, Rodriguez D, Feingold J, Renouil M, Munnich A, Westhof E, Föhling M, Lyonnet S, Henrion-Caude A. Mutation in a primate-conserved retrotransposon reveals a noncoding RNA as a mediator of infantile encephalopathy. *Proc Natl Acad Sci U S A*. 2012 Mar 27;109(13):4980-5. doi: 10.1073/pnas.1111596109. Epub 2012 Mar 12. PMID: 22411793; PMCID: PMC3323976.
54. Kirin M, McQuillan R, Franklin CS, Campbell H, McKeigue PM, Wilson JF. Genomic runs of homozygosity record population history and consanguinity. *PLoS One*. 2010 Nov 15;5(11):e13996. doi: 10.1371/journal.pone.0013996. PMID: 21085596; PMCID: PMC2981575.
55. Tournebise R, Chu G, Moorjani P. Reconstructing the history of founder events using genome-wide patterns of allele sharing across individuals. *PLoS Genet*. 2022 Jun 23;18(6):e1010243. doi: 10.1371/journal.pgen.1010243. PMID: 35737729; PMCID: PMC9223333.

56. Zhou K, Gheybi K, Soh PXY, Hayes VM. Evaluating variant pathogenicity prediction tools to establish African inclusive guidelines for germline genetic testing. *Commun Med (Lond)*. 2025 May 6;5(1):157. doi: 10.1038/s43856-025-00883-x. PMID: 40328947; PMCID: PMC12056225.
57. Gudmundsson S, Singer-Berk M, Watts NA, Phu W, Goodrich JK, Solomonson M; Genome Aggregation Database Consortium; Rehm HL, MacArthur DG, O'Donnell-Luria A. Variant interpretation using population databases: Lessons from gnomAD. *Hum Mutat*. 2022 Aug;43(8):1012-1030. doi: 10.1002/humu.24309. Epub 2021 Dec 16. PMID: 34859531; PMCID: PMC9160216.
58. Petrovski S, Goldstein DB. Unequal representation of genetic variation across ancestry groups creates healthcare inequality in the application of precision medicine. *Genome Biol*. 2016 Jul 14;17(1):157. doi: 10.1186/s13059-016-1016-y. PMID: 27418169; PMCID: PMC4944427.
59. Martin AR, Kanai M, Kamatani Y, Okada Y, Neale BM, Daly MJ. Clinical use of current polygenic risk scores may exacerbate health disparities. *Nat Genet*. 2019 Apr;51(4):584-591. doi: 10.1038/s41588-019-0379-x. Epub 2019 Mar 29. Erratum in: *Nat Genet*. 2021 May;53(5):763. doi: 10.1038/s41588-021-00797-z. PMID: 30926966; PMCID: PMC6563838.
60. Nunes K, Araújo Castro E Silva M, Rodrigues MR, Lemes RB, Pezo-Valderrama P, Kimura L, de Sena LS, Krieger JE, Catoia Varela M, de Azevedo LO, Aranha Camargo LM, Ferreira RGM, Krieger H, Bortolini MC, Mill JG, Sacuena P, Guerreiro JF, de Souza CMB, Veronese FV, Vianna FSL, Comas D, Pereira AC, Pereira LV, Hünemeier T. Admixture's impact on Brazilian population evolution and health. *Science*. 2025 May 15;388(6748):eadl3564. doi: 10.1126/science.adl3564. Epub 2025 May 15. PMID: 40373151.
61. Naslavsky MS, Scliar MO, Yamamoto GL, Wang JYT, Zverinova S, Karp T, Nunes K, Ceroni JRM, de Carvalho DL, da Silva Simões CE, Bozoklian D, Nonaka R, Dos Santos Brito Silva N, da Silva Souza A, de Souza Andrade H, Passos MRS, Castro CFB, Mendes-Junior CT, Mercuri RLV, Miller TLA, Buzzo JL, Rego FO, Araújo NM, Magalhães WCS, Mingroni-Netto RC, Borda V, Guio H, Rojas CP, Sanchez C, Caceres O, Dean M, Barreto ML, Lima-Costa MF, Horta BL, Tarazona-Santos E, Meyer D, Galante PAF, Guryev V, Castelli EC, Duarte YAO, Passos-Bueno MR, Zatz M. Whole-genome sequencing of 1,171 elderly admixed individuals from São Paulo, Brazil. *Nat Commun*. 2022 Mar 4;13(1):1004. doi: 10.1038/s41467-022-28648-3. Erratum in: *Nat Commun*. 2022 Mar 30;13(1):1831. doi: 10.1038/s41467-022-29575-z. PMID: 35246524; PMCID: PMC8897431.
62. Martínez-Magaña JJ, Genis-Mendoza AD, Villatoro Velázquez JA, Camarena B, Martín Del Campo Sanchez R, Fleiz Bautista C, Bustos Gamiño M, Reséndiz E, Aguilar A, Medina-Mora ME, Nicolini H. The Identification of Admixture Patterns Could Refine Pharmacogenetic Counseling: Analysis of a Population-Based Sample in Mexico. *Front Pharmacol*. 2020 Apr 22;11:324. doi: 10.3389/fphar.2020.00324. PMID: 32390825; PMCID: PMC7188951.
63. Chen E, Facio FM, Aradhya KW, Rojahn S, Hatchell KE, Aguilar S, Ouyang K, Saitta S, Hanson-Kwan AK, Capurro NN, Takamine E, Jamuar SS, McKnight D, Johnson B, Aradhya S. Rates and Classification of Variants of Uncertain Significance in Hereditary Disease Genetic Testing. *JAMA Netw Open*. 2023 Oct 2;6(10):e2339571. doi: 10.1001/jamanetworkopen.2023.39571. PMID: 37878314; PMCID: PMC10600581.
64. Magavern EF, Jacobs B, Warren H, Finocchiaro G, Finer S, van Heel DA; Genes & Health Research Team; Smedley D, Caulfield MJ. *CYP2C19* Genotype Prevalence and Association With Recurrent Myocardial Infarction in British-South Asians Treated With Clopidogrel. *JACC Adv*. 2023 Sep;2(7):None. doi: 10.1016/j.jacadv.2023.100573. PMID: 37808344; PMCID: PMC10550831.
65. Botton MR, Duconge J and Rodrigues-Soares F (2022) Editorial: Pharmacogenomics in neglected populations. *Front. Pharmacol*. 13:1081117. doi: 10.3389/fphar.2022.1081117.
66. Ocana A, Pandiella A, Privat C, Bravo I, Luengo-Oroz M, Amir E, Gyorffy B. Integrating artificial intelligence in drug discovery and early drug development: a transformative approach. *Biomark Res*. 2025 Mar 14;13(1):45. doi: 10.1186/s40364-025-00758-2. PMID: 40087789; PMCID: PMC11909971.
67. Duncan, L., Shen, H., Gelaye, B. *et al*. Analysis of polygenic risk score usage and performance in diverse human populations. *Nat Commun* **10**, 3328 (2019). <https://doi.org/10.1038/s41467-019-11112-0>.
68. Razia IT, Kanwal A, Riaz HF, Malik A, Ahsan M, Khan MS, Raza A, Sabir S, Sajid Z, Khan MF, Tahir RA, Sehgal SA. Recent Trends in Computer-aided Drug Design for Anti-cancer Drug Discovery. *Curr Top Med Chem*. 2023;23(30):2844-2862. doi: 10.2174/0115680266258467231107102643. PMID: 38031798.
69. Huang K, Xiao C, Glass LM, Critchlow CW, Gibson G, Sun J. Machine learning applications for therapeutic tasks with genomics data. *Patterns (N Y)*. 2021 Aug 9;2(10):100328. doi: 10.1016/j.patter.2021.100328. PMID: 34693370; PMCID: PMC8515011.
70. Paul D, Sanap G, Shenoy S, Kalyane D, Kalia K, Tekade RK. Artificial intelligence in drug discovery and development. *Drug Discov Today*. 2021 Jan;26(1):80-93. doi: 10.1016/j.drudis.2020.10.010. Epub 2020 Oct 21. PMID: 33099022; PMCID: PMC7577280.
71. Zhang, O., Lin, H., Zhang, X., Wang, X., Wu, Z., Ye, Q., Zhao, W., Wang, J., Ying, K., Kang, Y., Hsieh, C.-y., & Hou, T. (2025). Graph Neural Networks in Modern AI-aided Drug Discovery. arXiv preprint arXiv:2506.06915. <https://arxiv.org/abs/2506.06915>.
72. Wallach, I., Dzamba, M., & Heifets, A. (2015). AtomNet: A Deep Convolutional Neural Network for Bioactivity Prediction in Structure-based Drug Discovery. arXiv:1510.02855.

73. Yang, Z., Zeng, X., Zhao, Y. *et al.* AlphaFold2 and its applications in the fields of biology and medicine. *Sig Transduct Target Ther* **8**, 115 (2023). <https://doi.org/10.1038/s41392-023-01381-z>.
 74. Gu X, Aranganathan A, Tiwary P. Empowering AlphaFold2 for protein conformation selective drug discovery with AlphaFold2-RAVE. *Elife*. 2024 Sep 6;13:RP99702. doi: 10.7554/eLife.99702. PMID: 39240197; PMCID: PMC11379456.
 75. Hutter C, Zenklusen JC. The Cancer Genome Atlas: Creating Lasting Value beyond Its Data. *Cell*. 2018 Apr 5;173(2):283-285. doi: 10.1016/j.cell.2018.03.042. PMID: 29625045.
 76. Carrot-Zhang J, Chambwe N, Damrauer JS, Knijnenburg TA, Robertson AG, Yau C, Zhou W, Berger AC, Huang KL, Newberg JY, Mashl RJ, Romanel A, Sayaman RW, Demichelis F, Felau I, Frampton GM, Han S, Hoadley KA, Kemal A, Laird PW, Lazar AJ, Le X, Oak N, Shen H, Wong CK, Zenklusen JC, Ziv E; Cancer Genome Atlas Analysis Network; Cherniack AD, Beroukhim R. Comprehensive Analysis of Genetic Ancestry and Its Molecular Correlates in Cancer. *Cancer Cell*. 2020 May 11;37(5):639-654.e6. doi: 10.1016/j.ccell.2020.04.012. PMID: 32396860; PMCID: PMC7328015.
 77. Morselli Gysi D, do Valle Í, Zitnik M, Ameli A, Gan X, Varol O, Ghiassian SD, Patten JJ, Davey RA, Loscalzo J, Barabási AL. Network medicine framework for identifying drug-repurposing opportunities for COVID-19. *Proc Natl Acad Sci U S A*. 2021 May 11;118(19):e2025581118. doi: 10.1073/pnas.2025581118. PMID: 33906951; PMCID: PMC8126852.
-
1. Manrai AK, Funke BH, Rehm HL, Olesen MS, Maron BA, Szolovits P, et al. Genetic misdiagnoses and the potential for health disparities. *N Engl J Med*. 2016;375:655–65.